分类号：TP29　　单位代码：10335
密　级：无　　学　　号：21810180

浙江大学

硕士学位论文

中文论文题目：基于轨迹提取的鱼类异常行为监测

英文论文题目：Anomaly Detection of Fish Behaviors Based on Trajectory Extraction

申请人姓名：李星辉
指导教师：刘妹琴　教授
合作导师：无
学科(专业)：电气工程
研究方向：计算机视觉
所在学院：电气工程学院

论文递交日期　2021 年 1 月 15 日

中国知网　https://www.cnki.net

基于轨迹提取的鱼类异常行为监测

论文作者签名： 李星辉

指导教师签名： 刘妹琴

论文评阅人 1：李超勇/研究员/浙江大学

评阅人 2：包哲静/副教授/浙江大学

评阅人 3：赵辽英/教授/杭州电子科技大学

评阅人 4：姓名

评阅人 5：姓名

答辩委员会主席：赵航芳/教授/浙江大学

委员 1：张森林/教授/浙江大学

委员 2：刘妹琴/教授/浙江大学

委员 3：郑荣濠/副教授/浙江大学

委员 4：

委员 5：

答辩日期 2021 年 3 月 9 日

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

致谢

时间过得真快，转眼间研究生生涯即将结束。在这两年半的时间里，我成长了许多，在此感谢在科研、学习和生活上帮助和支持我的人。

感谢我的导师刘妹琴老师。刘老师有着严谨的治学态度、勤奋的工作精神，是我要学习的榜样。刘老师在我懈怠不前时警醒督促，在我遇到困难时支持帮助，让我获得了很大的成长。感谢课题组的郑荣濠老师，在课题研究、论文撰写上给了我很多帮助。感谢课题组的张森林老师、何衍老师、樊臻老师，对我的研究提出了指导性的意见。

感谢课题组的同学们。感谢已经毕业的刘思阳、白天、刘凯鉴、孙博、陈士杰师兄，带我融入了课题组环境。感谢即将毕业的王祺师兄、赵恒飞、楼冠廷、李丹一、邓宇豪、吴子晔、穆亚楠、沈莹、李文阁，感谢互相帮助、共同成长、一起玩耍的这段日子，愿我们前途光明、一帆风顺。感谢电机楼 218 室的徐阳、王根檑、卢晨、陈喜来、白若飞、叶卓勋、霍嘉熹以及教二 103 室的葛致远，你们的加入带来了蓬勃向上的朝气，未来是属于你们的。

感谢我的父母和家人，感谢你们二十多年的培养，在我求学的过程中一如既往地支持和关心我。祝愿你们身体健康、笑口常开。

本论文的研究工作得到了 NSFC—浙江两化融合联合基金项目（重点支持项目）—“基于水下无线传感器网络的深水网箱养殖智能化监测关键技术研究”（No.U1809212）和浙江省重点研发计划项目—“面向现代渔业与航海安全的信息化装备技术与应用示范—基于大洋烽火台的商用海洋信息监测潜浮标系统”（No.2018C03030）的资助，对此表示感谢。

李星辉

2021 年初于求是园

中国知网 https://www.cnki.net

摘要

中国是渔业大国，也是最大的水产品出口国。在水产养殖过程中，不恰当的水体环境会影响鱼类的正常生长发育，并伴随着一些应激行为反应。如果没有及时发现这些异常行为并采取有效措施，往往会导致鱼群的病害甚至大面积死亡，因此监测鱼类行为势在必行。本文基于公开的 MHK 水下鱼类视频数据集和 Fish4Knowledge 水下鱼类轨迹数据集，分别研究鱼类游动轨迹提取技术以及轨迹异常判别技术，并最终综合为鱼类异常行为在线监测算法。

针对轨迹提取，本文首先训练目标检测模型 Faster RCNN 对水下鱼类图像进行检测，用数据增强提升模型性能。接着提出了轨迹关联方法，依据相似关系定义两个检测框的关联度，并利用时间上下文信息优化轨迹结果。针对轨迹异常判别，本文首先利用 GRU 网络（Gated Recurrent Unit）设计了面向时间序列型轨迹数据的自编码器模型，通过无监督学习将轨迹数据变换为固定长度的编码特征。接着提出了分别基于重构误差和聚类中心距离的两种异常判别标准。最后，本文综合了轨迹提取和异常判别两部分，初步实现了在线监测算法。

水下鱼类视频的测试结果表明，本文提出的轨迹提取方法能够正确获取鱼类的游动轨迹，并减少漏检、误检错误，有效提升整体指标。鱼类轨迹数据集的测试结果表明，本文提出的基于自编码器的特征变换方法优于人工构造特征的方法，异常判别标准能够有效捕捉到异常轨迹。

关键词：目标检测，轨迹提取，异常检测，自编码器，鱼类行为

中国知网 https://www.cnki.net

Abstract

China is a big fishery country and has always been the largest exporter of aquatic products. In the process of aquaculture, improper water environment will affect the growth of fish, and bring some abnormal behaviors. If these abnormal behaviors are not detected in time and no effective measures are taken, it will often lead to fish diseases and even large-scale deaths. Therefore, it is imperative to monitor fish behaviors. Based on the underwater fish video dataset, MHK, and the underwater fish trajectory dataset, Fish4Knowledge, this thesis separately studies the technology of fish swimming trajectory extraction and the technology of abnormal trajectory detection, and finally integrates them into an online monitoring algorithm.

For trajectory extraction, this thesis first trains Faster RCNN, an object detection model in deep learning, to detect underwater fish images. Data augmentation is used to enhance the model performance. A trajectory association method is then proposed, which defines the degree of relation between two bounding boxes and optimizes the results using temporal context information. For abnormal trajectory detection, this thesis first uses the GRU network (Gated Recurrent Unit) to design an autoencoder model for trajectory time series data, and transforms the trajectory data into fixed-dimensional feature through unsupervised learning. Then, two criteria based on reconstruction error and distance from cluster centers are proposed. Finally, this thesis combines the two parts of trajectory extraction and anomaly detection, and preliminarily completes an online monitoring algorithm.

The results of the underwater fish test video show that the trajectory extraction method can correctly obtain the swimming trajectory of fish, reduce missed detection and false detection errors, and effectively improve the overall performance. The results of fish trajectory dataset show that the feature transformation method based on autoencoder is better than the method of artificial features, and the two anomaly detection criteria can effectively capture the abnormal trajectory.

Keywords: Object Detection, Trajectory Extraction, Anomaly Detection, Autoencoder, Fish Behaviors

中国知网 https://www.cnki.net

目录

致谢 I
摘要 III
Abstract V
目录 VII
图目录 XI
表目录 XIII
1 绪论 1
1.1 研究背景及意义 1
1.2 国内外研究现状 2
1.2.1 鱼类行为监测中的计算机视觉技术 2
1.2.2 轨迹提取技术 2
1.2.3 轨迹异常判别方法 4
1.3 研究内容及论文结构 4
2 基于 Faster RCNN 的鱼类检测 7
2.1 水下鱼类图像数据集 7
2.2 鱼类检测模型 8
2.2.1 数据预处理及数据增强 10
2.2.2 Faster RCNN 模型结构 11
2.2.3 目标检测的后处理操作 13
2.2.4 mAP 评价指标 14
2.3 结果与分析 16
2.3.1 硬件与软件环境 16
2.3.2 不同方法的 AP 指标对比 16
2.3.3 错误案例分析 19
2.4 小结 21
3 基于检测结果的轨迹关联 22
3.1 关联度的计算 22
3.2 基于关联度的匹配 24
3.2.1 匈牙利匹配算法 24

中国知网 https://www.cnki.net

3.2.2 贪心匹配算法 26
3.3 轨迹关联结果优化 27
3.3.1 连接相近的轨迹段 27
3.3.2 删除较短的轨迹段 28
3.4 结果与分析 28
3.4.1 不同实验设置下的消融实验 29
3.4.2 连接和删除的影响 31
3.4.3 中心距离关联度的影响 32
3.5 小结 33
4 基于特征变换的轨迹异常判别 34
4.1 水下鱼类轨迹数据集 34
4.1.1 Fish4Knowledge 数据集 34
4.1.2 数据集分析 35
4.2 基于自编码器的特征变换 35
4.2.1 自编码器原理 37
4.2.2 GRU 结构 38
4.2.3 自编码器网络结构设计 39
4.2.4 结果与分析 41
4.3 异常判别方法 42
4.3.1 基于自编码器重构误差的异常判别 42
4.3.2 基于聚类中心距离的异常判别 43
4.3.3 结果对比与分析 45
4.4 小结 46
5 鱼类异常行为在线监测 47
5.1 在线监测算法 47
5.1.1 在线方式与离线方式的比较 47
5.1.2 轨迹关联修改 48
5.1.3 编码器修改 48
5.1.4 自编码器轨迹训练集制作 49
5.1.5 异常轨迹的在线判别规则 50
5.2 结果与分析 50

中国知网 https://www.cnki.net

5.3 小结 51
6 总结与展望 52
6.1 全文总结 52
6.2 下一步的研究方向 52
参考文献 55
攻读硕士学位期间的主要成果 61

中国知网 https://www.cnki.net

图目录

图 1.1 本文的研究内容及其联系 5
图 2.1 MHK 数据集三个场景的示例图像 9
图 2.2 数据增强示例 11
图 2.3 Faster RCNN 结构 12
图 2.4 交并比等于重叠面积除以覆盖面积 13
图 2.5 后处理操作示例 15
图 2.6 数据增强前后的 Precision-Recall 曲线 18
图 2.7 检测模型错误案例 20
图 3.1 中心距离关联度和概率相似度计算示例 23
图 3.2 连续多帧预测框的二分图匹配 25
图 3.3 概率大于某个阈值的预测框数目占比 28
图 3.4 在不同时间点的轨迹提取结果 30
图 3.5 连接、删除操作前后轨迹结果的变化过程 31
图 3.6 删除操作前后，AP 指标随连接参数 k 的变化 32
图 3.7 不同采样间隔下，采用中心距离关联度对 AP 指标的影响 32
图 4.1 Fish4Knowledge 轨迹数据示例 35
图 4.2 Fish4Knowledge 轨迹数据长度分布 37
图 4.3 自编码器框架 37
图 4.4 RNN 的循环结构 38
图 4.5 RNN 的内部结构 39
图 4.6 自编码器网络结构 40
图 4.7 轨迹特征数据的 t-SNE 可视化 41
图 4.8 改变重构误差阈值，正类/负类/综合准确率的变化 43
图 4.9 改变中心距离阈值，正类/负类/综合准确率的变化 44
图 5.1 离线/在线运行方式比较 47
图 5.2 编码特征的动态更新 48
图 5.3 提取出的轨迹数据长度分布 49
图 5.4 在线运行结果 50

中国知网 https://www.cnki.net

表目录

表 2.1 一些水下鱼类数据集概况 8
表 2.2 MHK 数据集三个场景的数据概况 8
表 2.3 MHK 数据集划分 9
表 2.4 二分类任务中预测值与真实值的四种情况 14
表 2.5 硬件与软件环境 17
表 2.6 不同方法的 AP 指标 (%) 17
表 2.7 数据增强前后的最终召回率 (%) 18
表 3.1 不同实验设置下的 AP 指标 (%) 29
表 4.1 Fish4Knowledge 轨迹数据形式 34
表 4.2 不同样本集的重构误差统计量 43
表 4.3 不同方法在 Fish4Knowledge 轨迹数据集上的准确率 45
表 5.1 在线运行时各个功能模块的耗时情况 (秒) 51

中国知网 https://www.cnki.net

1 绪论

1.1 研究背景及意义

渔业是中国大农业中发展最快的产业，中国是重要的国际渔业市场，自 2002 年以来一直占据着最大水产品出口国的地位[1]。2019 年，全国水产品总产量为 6480.36 万吨，渔业产值为 2934.49 亿元[2]。

在水产养殖过程中，鱼类对于水体的盐度变化、水体内溶氧量的变化、水体温度的变化、环境的光照强度和不同光照颜色等外部环境的改变和刺激是非常敏感的[3]。不恰当的水体环境会影响鱼类的正常生长发育，并伴随着一些应激行为反应。如果没有及时发现这些异常行为并采取有效的措施，往往会导致鱼群的病害甚至出现大面积死亡的现象。仅 2019 年由于渔业灾情造成直接经济损失达 156.37 亿元[2]，因此监测鱼类行为势在必行。

传统的做法是人工现场观测，但人工方法耗时费力，不但受人为主观因素的影响较大，而且观测范围和观测时间均受到诸多限制。随着科学技术的发展以及自动化理念融入各行各业，大量水下装备和搭载工具的出现，大大拓展了人们对水下环境的观测范围和观测手段，比如水下摄像头、声纳、AUV（Autonomous Underwater Vehicle，自主水下航行器）、ROV（Remote Operated Vehicle，遥控无人潜水器）等。与此同时，计算机视觉、声纳信号处理、多传感器融合等方法不断革新[4]，为自动化监测提供了条件。其中，计算机视觉技术利用水下摄像头采集光学图像，具有分辨率高、信息量丰富的特点，在短距离的水下目标探测任务中占据突出优势[5]。已经有不少的研究将计算机视觉技术应用于水产领域[6-8]。作为最常见和最具成本效益的监测手段，计算机视觉技术能够对鱼类进行长时间连续的非干扰式的监测，为鱼类健康监控与异常预警提供保障。然而相比陆上环境，水下图像存在噪声干扰多、纹理特征模糊、照明光斑、对比度低以及颜色失真等一些问题[5]，分析水下图像具有更大的挑战。

综上所述，基于水下光学图像，利用计算机视觉技术，研究水下鱼类行为自动化监测技术，做到对鱼类异常状态的及时预警，能够推动水产养殖业的健康持续发展。本文基于水下鱼类视频数据集和水下鱼类轨迹数据集，分别研究鱼类游动轨迹提取技术以及轨迹异常判别技术，并最终综合为鱼类异常行为在线监测算法。

中国知网 https://www.cnki.net

1.2 国内外研究现状

1.2.1 鱼类行为监测中的计算机视觉技术

到目前为止，许多鱼类行为监测的工作都是在实验室条件下进行的。大多数方法的流程比较类似，一般均要经过图像预处理、前景分割以及目标跟踪[9-14]。图像预处理的做法有灰度化、滤波去噪等。前景分割分为去除背景和提取前景两个步骤，去除背景的做法有帧间差分法、光流法、减背景法、分水岭算法等，前景提取一般要经过二值化以及形态学处理。目标跟踪最常见的是 CamShift 算法和卡尔曼滤波算法。上述流程能够提取出每条鱼的个体运动信息，但对检测识别算法的要求较高。

一些研究者提出了直接量化鱼群行为的方法，无需识别和跟踪个别鱼类行为。于欣等人[15] 利用光流法得到目标鱼群的运动矢量，进而统计得到速度与转角这两个行为特征的联合直方图与联合概率分布。Sadoul 等人[16] 从像素级轮廓的周长和面积出发，定义了集群强度和活动强度等指标。卢焕达等人[17] 提取前景分割后鱼群位置的均值、方差、歪斜度、峰态和能量 5 个参数，构成每幅图像的鱼群运动特征参数。然而，直接研究群体行为的做法利用的是较为抽象的特征，可解释性较差，在研究者的特定场景和特定任务中能取得不错的效果，但难以推广到其它场景中去。

近年来，在许多计算机视觉任务中，深度神经网络，尤其是卷积神经网络（Convolutional Neural Network，CNN），相比传统图像处理算法表现得更好。CNN 从低级的点线面到高级的语义概念逐层次提取特征，更容易把握图像的全局信息和上下文信息。一些研究利用深度学习的方法，完成了对水下鱼类的分类[18]、检测[19, 20]、轨迹分析[21] 等任务。

1.2.2 轨迹提取技术

轨迹提取是个笼统的概念，目的是从视频中提取出感兴趣目标的轨迹，相关领域有单目标跟踪（Single Object Tracking，SOT）、多目标跟踪（Multiple Object Tracking，MOT）、视频目标检测（Object Detection from Video，VID）等。它们的含义有一些差别。

在单目标跟踪任务中，通常需要给出一个初始的矩形框区域，矩形框包含了感兴趣的目标或者特征，之后在后续的视频帧中逐渐调整矩形框的位置来跟踪目标。典型的算法是传统图像处理的 CamShift 跟踪算法（Continuously Adaptive Mean-SHIFT）。CamShift 算法的基本思想是对视频的连续帧应用色彩反向投影及 MeanShift 运算，并将上一帧搜索窗口的位置和大小作为下一帧搜索窗口的初始值，不断迭代下去。色彩反向投影指的

中国知网 https://www.cnki.net

是利用色彩特征而构造的概率图，MeanShift 运算从概率图中寻找到概率极大值的位置，从而确定此次跟踪的位置。深度学习方法 SamRPN[22] 利用模板比对的思想来完成单目标跟踪。首先采用参数相同的孪生网络分别提取模板（初始框）与当前帧的特征，接着将两部分特征输入修改后的 RPN 网络（Region Proposal Networks，区域生成网络），在 RPN 中通过比对生成一些候选框。SamRPN++[23] 进一步解决了 SamRPN 提取特征时不能采用深层网络的问题，带来了更好的性能。

在朴素的意义上，可以对多个初始目标应用单目标跟踪算法来实现多目标跟踪。但由于目标数目动态变化、类别不止一种等原因，如今大多数多目标跟踪算法是基于目标检测的，即用目标检测模型为视频的每一帧都给出检测结果，再进行帧间数据关联。这样的方法不需要给出初始框。SORT 算法[24] 是一种简单有效的多目标跟踪算法，其主要思想有：利用卡尔曼滤波器预测下一帧的位置；采用交并比作为预测框的关系度量；通过匈牙利算法来进行关联。DeepSORT 算法[25] 是 SORT 算法的改进版本，添加了一个外观模型，通过 CNN 网络提取出 128 维特征向量，来评测两块区域的外观相似度。多目标跟踪的主要评价指标是 MOTA（Multiple Object Tracking Accuracy），MOTA 综合了预测结果的漏检、误检以及跟踪时目标 ID 切换的次数这三个因素。

视频目标检测是图像目标检测的拓展，主要是为了满足视频监控、车辆辅助驾驶等领域的需求，因为仅采用图像目标检测不能很好地处理视频中运动模糊、遮挡、光照条件变化等问题。ILSVRC2016 竞赛[26] 的视频目标检测任务包含一个子任务，将检测结果的时序一致性也作为评测指标，因此一些视频目标检测方法仍然关注轨迹关联。视频目标检测方法大致上分为两类，一类是预测框层面的后处理方法，另外一类是特征层面的融合模型方法。后处理方法如 T-CNN[27] 和 Seq-Bbox[28]。T-CNN 采用上下文抑制来减少多分类的误检，利用光流法的运动传播来减少漏检。Seq-Bbox 先做轨迹段关联，再对轨迹段进行优化。融合模型方法如 FGFA[29]，它将之前帧的特征扭曲变换后与当前帧的特征融合，再将融合后的特征送入检测器。视频目标检测的评价指标与图像目标检测一样，是 mAP（mean Average Precision），mAP 综合了预测结果的漏检、误检这两个因素。

多目标跟踪与视频目标检测都依赖于图像目标检测。目标检测是近年来深度学习的热门领域之一。目标检测模型有很多，典型的分类是单阶段和双阶段。双阶段模型以 RCNN 系列[30, 31] 为代表，做法是先提取出大量感兴趣区域，再对这些区域进行标签的分类以及预测框的回归微调。单阶段模型以 YOLO[32]、SSD[33] 为代表，它们不需要提取感兴趣区域，而是在大量预设位置获得分类和回归的结果。一般来说，双阶段模型精度更高，单阶段模型速度更快。

中国知网 https://www.cnki.net

综上所述，尽管单目标跟踪、多目标跟踪、视频目标检测在技术实现上有所差异，但它们都需要利用视频的上下文信息来满足视频目标识别的需求。本文针对水下鱼类视频数据集，训练双阶段目标检测模型 Faster RCNN[30]，并根据多目标跟踪、视频目标检测的思想，设计了轨迹关联的方法，从而完成鱼类游动轨迹提取的任务。

1.2.3 轨迹异常判别方法

异常判别不是一个很明确的说法，它只表明了目的，在本小节中用异常检测来代替这个说法。异常检测（Anomaly Detection）是机器学习的一个重要分支，一般指的是，已知大量正常数据和少量（或没有）异常数据，如何找到异常点（或叫离群点），或判断新来的数据是否是异常点。异常检测是一个很宽泛的概念，不同场景的问题定义和侧重点有所差异。概括来说，异常检测方法包括但不限于：基于统计的方法，如多变量高斯分布；基于密度的方法，如 LOF[34]（Local Outlier Factor）；基于模型的方法，如孤立森林[35]。

在关于轨迹的一些研究中，研究者处理数据的方法和异常检测的方法也各不相同。Beyan 等人[36] 将轨迹定义为一些简单运动模式的组合，并依据运动模式定义了一套规则，采用级联分类器找到异常轨迹。Beyan 等人[37] 在前面工作的基础上，按照固定的计算方式从轨迹数据中得到一些速度、加速度、转角、邻近区域、回环、曲率等多方面的特征，其中速度特征包括最大值、最小值、平均值、标准差、过零点次数等等，所有特征共 776 维，最后采用基于聚类的层次分类器。Li 等人[38] 用三次样条曲线来拟合轨迹，得到固定数目的样本点，异常检测方法是给定一些已知的轨迹代表，对一条新轨迹的表示进行稀疏重建，依据稀疏系数以及残差判断是否异常。李明之等人[39] 在交通监控场景，引入空间位置、运动速度、运动方向和大小尺寸等特征参数对轨迹进行描述和聚类，最后采用高斯概率模型和贝叶斯最优化方法判断新轨迹属于哪一类。

综上所述，对于轨迹异常判别问题，需要具体分析并依靠实验验证。本文第四章将详细讨论这个问题。

1.3 研究内容及论文结构

本文的研究对象是 MHK 水下鱼类视频数据集[20] 和 Fish4Knowledge 水下鱼类轨迹数据集[37]，研究路线是从鱼类的个体行为出发，先从视频中提取出鱼类的游动轨迹，再依据轨迹信息进行异常判别，如图 1.1所示。轨迹提取分为两个步骤，先利用目标检测模型处理视频的每一帧获取检测结果，再通过关联匹配的方法连成游动轨迹。

中国知网 https://www.cnki.net

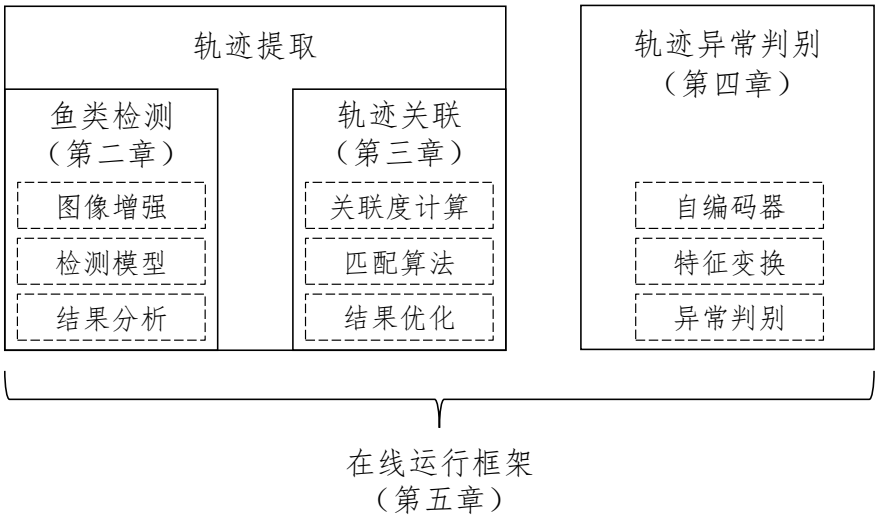


图 1.1: 本文的研究内容及其联系

本文的结构安排如下：

- 第一章：绪论。这一章介绍了本文的研究背景和意义，并从鱼类行为监测中的计算机视觉技术、轨迹提取技术、轨迹异常判别方法三个方面总结了相关工作，最后介绍了本文的主要研究内容和论文的结构。
- 第二章：基于 Faster RCNN 的鱼类检测。这一章采用深度学习的 Faster RCNN 目标检测模型对水下鱼类图像进行检测，重点介绍了水下鱼类图像数据集情况、数据预处理及数据增强过程、模型结构、后处理过程以及检测任务的 mAP 评价指标。基于这些内容，最后对比了不同方法的性能，并分析了存在的问题以及错误案例。
- 第三章：基于检测结果的轨迹关联。这一章提出了一种轨迹关联方法，将第二章中检测模型对视频每一帧的预测结果关联成鱼类的游动轨迹。首先对问题进行建模，并从如何计算两个预测框的关联度、如何利用关联度获得匹配关系、如何对轨迹结果进行优化三个方面详细介绍了轨迹关联的过程。最后对各个模块和组件进行了全面的实验，并给出了相关的分析。由于利用了视频的时间上下文信息，轨迹提取后能够有效地提升整体的指标。
- 第四章：基于特征变换的轨迹异常判别。这一章在水下鱼类轨迹数据集上进行研究，探讨了数据集情况以及解决方案。异常判别的思路是，设计一个自编码器进行无监督训练，将时间序列型的轨迹数据变换为固定长度的编码向量，接着分别采用自编码器重构误差和聚类中心距离两种评测标准判别异常。相较于传统的人

中国知网 https://www.cnki.net

工提取特征的方法，准确率有一定提升。

- 第五章：鱼类异常行为在线监测。这一章将第二章、第三章、第四章的内容，综合为统一的在线监测算法，以实现鱼类异常行为的在线监测。
- 第六章：总结与展望。这一章总结了全文的工作以及取得的成果，并进一步指出目前研究工作的不足之处以及未来的研究方向。

中国知网 https://www.cnki.net

2 基于 Faster RCNN 的鱼类检测

本章采用深度学习的 Faster RCNN 目标检测模型完成水下图像中鱼类检测的工作，重点介绍了水下鱼类图像数据集情况、数据预处理及数据增强过程、模型结构、后处理过程以及检测任务的 mAP 评价指标。基于这些内容，最后对比了不同方法的性能，并分析了存在的问题以及错误案例。

2.1 水下鱼类图像数据集

近年来，在目标检测等计算机视觉任务中，采用深度学习模型的方法占主导地位。深度学习方法的一个明显的特点是，相较于传统图像处理方法，需要大量的训练数据。尽管深度学习的流行催生了大量图像、视频数据集的公开，但具体到水下鱼类场景，在网络上能搜集到的公开数据集仍然较少。表 2.1总结了一些网络上公开的水下鱼类数据集的概况。

Fish4Konwledge 数据集于 2010~2013 年间在台湾海域拍摄得到，覆盖多种海洋场景，并具有多种类型的标注信息，主要被用于鱼类检测和品种识别等任务，连续多年是 LifeCLEF[40] 竞赛的赛题之一。然而，Fish4Knowledge 数据集较老，视频分辨率为 320 × 240，裁剪后图像大多分辨率为 100 × 100 左右，因此不是一个很好的研究对象。QUT fish data 和 Labeled fish in the wild 两个数据集不是鱼类连续游动的视频形式，因此不能作为轨迹提取与分析的对象。DeepFish 数据集的标注信息较少，The Brackish Dataset 数据集质量一般。综合考虑，轨迹提取任务采用 MHK 数据集作为研究对象。

MHK 数据集包含三个场景，不同场景的数据差异较大。这三个场景的数据概况如表 2.2，示例图像如图 2.1，红色矩形框是数据集的标注信息，代表此位置有一条鱼。Wells Dam 场景的数据采集于水下固定的鱼类游动通道，且采集设备、光线等条件较好，因此数据质量较高，第三章的轨迹提取任务主要将 Wells Dam 数据作为研究对象。Voith Hydro 场景的数据实际上是三个不同角度摄像头的组合图像，由于角度跟焦距等一些原因，图像质量很差。Igiugig 场景的数据质量最差，且包含鱼的帧数目只占 3%，因此很难利用起来。MHK 数据集是 LifeCLEF 2017 竞赛[41] 的赛题之一（仅有一个参赛组提交了结果）。

MHK 数据集划分训练集、测试集的情况如表 2.3。划分比例大致为训练集 80%，测试集 20%。由于数据集的图像来自视频帧，为了保证训练、测试过程的科学性，同一段

中国知网 https://www.cnki.net

视频的帧或者同时属于训练集，或者同时属于测试集。

表 2.1: 一些水下鱼类数据集概况

数据集	来源/场景	标注图像数目	标注类型	是否视频
Fish4Knowledge[42]	台湾海域热带鱼	多余 20000	像素点	部分是
QUT fish data[43]	澳大利亚生物数据库	3960	矩形框	否
Labeled fish in the wild[44]	南加州湾海域	929	矩形框	否
MHK[20]	三个场景差异较大	多余 20000	矩形框	是
The Brackish Dataset[45]	单一场景，多种类别	14518	矩形框	是
DeepFish[46]	20 个不同场景	分别 39766 / 3200 / 620	有无二分类 / 定位点 / 像素点	是

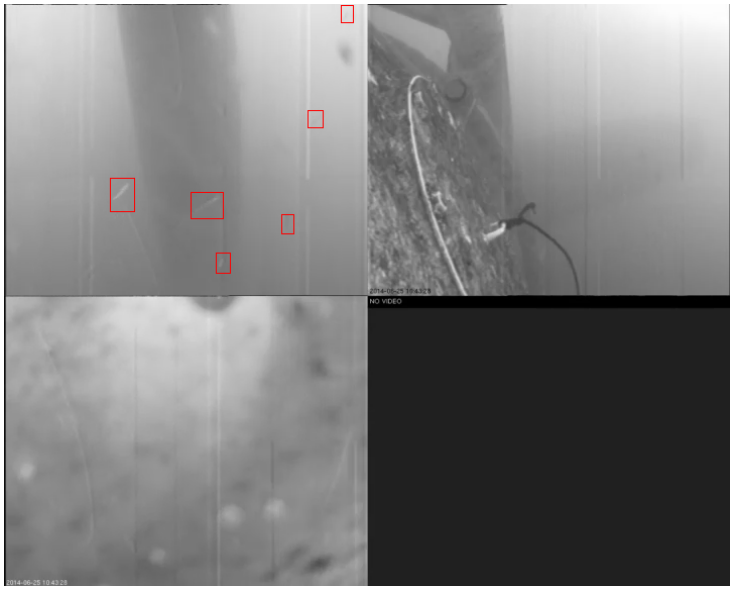
表 2.2: MHK 数据集三个场景的数据概况

场景	Voith Hydro	Wells Dam	Igiugig
分辨率	720 × 576	1280 × 960	320 × 240
帧率	15 fps	30 fps	10 fps
颜色空间	灰度图	RGB 图	RGB 图
帧总数	15918	24000	30277
包含鱼的帧数目	7663 (48%)	13405 (55%)	1002 (3%)

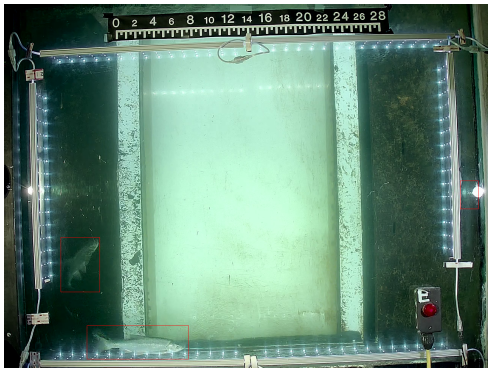
2.2 鱼类检测模型

目标检测的任务是，在图像上每一条鱼出现的位置，都给出一个矩形框作为预测结果。近年来深度学习方法占主导地位，因此选用深度神经网络中的目标检测模型 Faster

中国知网 https://www.cnki.net



(a) Voith Hydro



(b) Wells Dam



(c) Igiugig

图 2.1: MHK 数据集三个场景的示例图像

表 2.3: MHK 数据集划分

场景	训练集 总和 = 有鱼 + 无鱼	测试集 总和 = 有鱼 + 无鱼	总计 总和 = 有鱼 + 无鱼
Voith Hydro	12819 = 6046 + 6773	3099 = 1617 + 1482	15918 = 7663 + 8255
Wells Dam	19200 = 11260 + 7940	4800 = 2145 + 2655	24000 = 13405+10595
Igiugig	22497 = 817 + 21680	7780 = 185 + 7595	30277 = 1002 + 29275
总计	54516 = 18123+36393	15679 = 3947 + 11732	70195 = 22070+48125

中国知网 https://www.cnki.net

RCNN[30]，代码实现基于 Python 语言的 MMDetection 框架[47]。Faster RCNN 是典型的双阶段模型，各个组件较为灵活、容易扩展，且模型的准确率较高。对于“鱼”单类别来说，目标检测模型完成的工作，类似于传统图像处理的阈值分割与前景提取，不过与这些方法相比，CNN 能更好地提取图像的特征，因而能够适应较复杂的场景。

2.2.1 数据预处理及数据增强

数据指的是图像数据和标注框数据。数据在送进深度神经网络之前，需要做一些预处理操作，并且为了增加训练数据的多样性、让模型获得更好的表现，通常要对训练数据做大量的数据增强操作（尤其是针对视频数据集）。训练数据和测试数据的处理过程是不同的。另外，当图像数据在空间上进行改变后，标注框数据应当做出相应的改变。

训练数据的处理过程如下：

(1) 数据增强-颜色抖动。包括在 RGB 空间调整亮度（整体加减随机值）、对比度（整体乘以随机系数），在 HSV 空间调整饱和度（乘以随机系数）、色调（加减随机值）。值得一提的是，每个操作除了调整的参数是随机的，是否进行该操作也是随机的，通常取 50% 的概率，这样保证了大部分情况下处理后得到的图像与原图像的差距不会那么大。下面的几种数据增强操作也大多适用 50% 的概率。

(2) 数据增强-随机放置。做法是生成一张纯色图像作为画布，像素值填充为 RGB 图像均值，画布尺寸随机但保证大于原图，接着将原图放置在画布的随机位置。随机放置主要是为了配合下面的随机裁剪操作。

(3) 数据增强-随机裁剪。随机裁剪出图像中的一块，为了避免极端情形，对最小裁剪尺寸和裁剪后标注框的完整度进行限制。本章实现中最小裁剪尺寸是原始尺寸的 30%。

(4) 固定缩放。将图像缩放到固定尺寸，一定程度上让网络模型的训练更稳定。可以不保持原有的宽高比。

(5) 数据增强-随机翻转。以 50% 的概率进行水平翻转。

(6) 图像数据标准化。模型中提取特征的主干网络一般在超大图像数据集上训练，一些预训练好的主干网络对图像数据的输入有标准化的要求，即让图像像素值基本处于均值为 0、标准差为 1 的正态分布上。标准化操作有利于网络模型的数值计算过程。

(7) 固定填充。模型支持宽高都为 32 的倍数的任意尺寸输入，因此通过填充一些行列将图像宽高都调整为 32 的倍数。

对于测试数据，去掉了所有的数据增强操作，处理过程如下：

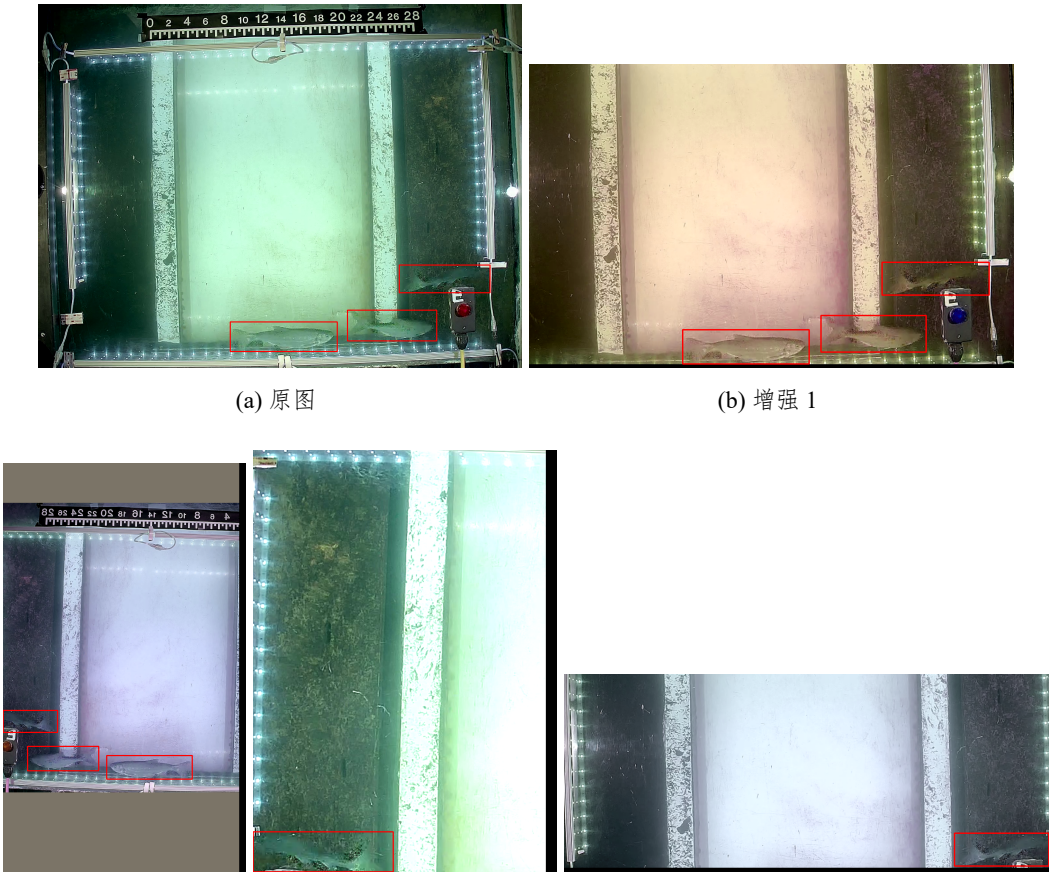
(1) 固定缩放。为了不改变图像的视觉感受，缩放时保持原有的宽高比。

中国知网 https://www.cnki.net

(2) 图像数据标准化。与训练数据一致。

(3) 固定填充。与训练数据一致。

对同一张图像进行随机增强，结果如图 2.2所示，获得不同的增强后图像，它们的尺寸与颜色各异。



(a) 原图 (b) 增强 1

(c) 增强 2 (d) 增强 3 (e) 增强 4

图 2.2: 数据增强示例

2.2.2 Faster RCNN 模型结构

本章实现中用到的 Faster RCNN 的结构如图 2.3所示，各个组件的功能如下：

- ResNet50[48] 和 FPN[49]（Feature Pyramid Networks，特征金字塔网络），用于从图像中提取特征。和其他用到卷积神经网络的计算机视觉任务一样，利用通用的主干网络从图像中提取特征，这里用到 ResNet50，并采用在 ImageNet[50] 上预训练好的网络参数作为初始化参数。ResNet 通过卷积层之间的跳跃连接，一定程度上解决了网络层数增多后梯度爆炸、梯度消失的问题。FPN 通过金字塔状的连接提升了

中国知网 https://www.cnki.net

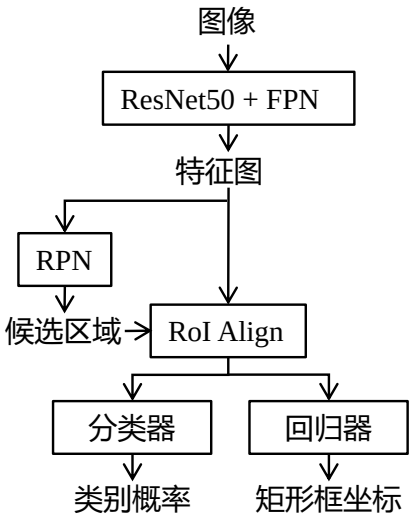


图 2.3: Faster RCNN 结构

主干网络在图像的不同尺度上提取特征的能力，进而影响模型的性能。图像经过 ResNet 和 FPN，得到特征图（Feature Map）。

- RPN（Region Proposal Networks，区域生成网络）。RPN 是双阶段模型的典型模块，功能是生成大量的 ROI 区域（Region of Interest，感兴趣区域）。这些 ROI 区域呈矩形状，与目标检测任务的输出类型一致。从分工上讲，RPN 的作用是粗筛，目的是忽略绝大多数的背景区域，而筛选出一些候选的 ROI 区域。评价 RPN 性能的指标是召回率（Recall），即真实的目标框是否在这些候选 ROI 区域中。RPN 作用在特征图上，生成候选区域的坐标。
- ROI Align[31]。利用 RPN 的候选区域的坐标，映射回特征图上，找到该候选区域的局部特征图，接着将该局部特征图池化为固定尺寸，一般为 7×7。之所以需要池化到固定尺寸，是因为网络模型的输出层一般是全连接层，卷积层对输入尺寸不敏感，而全连接层对输入尺寸敏感。ROI Align 是 ROI Pooling 的升级版，主要解决了 ROI Pooling 对坐标的数值量化而造成位置偏差的问题，提升了模型的准确性。
- 分类器和回归器。分别将该 7×7 的池化特征，输入到分类网络和回归网络中，得到该区域的类别概率以及针对该候选区域的坐标调整参数。利用坐标调整参数，微调该候选区域的位置，并映射到原图，最终获得预测的矩形框坐标。相对于 RPN 来说，这一步骤相当于精筛。

在具体应用时，有一些需要注意的问题，训练过程与测试过程也有较大差异，比如正负样本的采样、损失函数的设计，这里不再赘述。

中国知网 https://www.cnki.net

2.2.3 目标检测的后处理操作

图像分类任务是对每张图像输出一个类别标签和一个 0~1 的概率值。而对于目标检测任务来说，目标的位置、个数都是不确定的，这让网络模型复杂了许多。由于目标个数的不确定，Faster RCNN 及其他一些模型的做法是生成大量的候选结果，再选取其中把握较高的。对候选结果的筛选叫做后处理操作。

- NMS（Non-Maximum Suppression，非极大值抑制）。候选结果是非常多的（成千上万个），尤其在有目标的位置，网络模型会给出大量的预测框，这些预测框在位置上非常接近，但实际上只希望一个目标对应一个预测框。NMS 的工作是使局部区域内只保留一个置信度最高的预测框。NMS 是目标检测等任务的一个重要工具，同时也是一个研究方向，已经有一些研究者针对不同的应用场景提出了一些 NMS 的变体。NMS 用交并比（Intersection over Union，IOU）来定义两个矩形框的相似程度，IOU 的计算方式是两个矩形框重叠部分的面积除以两个矩形框覆盖部分的面积，如图 2.4所示。设定一个 NMS 阈值，当两个矩形框的交并比大于该阈值，则认为这两个矩形框是靠近的，经过 NMS 后最多只能存在一个。NMS 阈值一般取 0.5~0.7，过大则起不到局部抑制的作用，过小则影响密集目标的检测。
- 概率阈值。每个预测框都有一个概率值，概率越大，则认为该预测结果越有把握。因此，设定一个概率阈值，删去预测概率低于该阈值的预测框，只保留预测概率较大的预测框。
- 最大预测框数目。一张图像中的真实目标个数通常较少，设定一个最大预测框数目，典型值是 100，只保留前 100 个概率最大的预测框。这样能够减少无用的计算量，将结果规范化。

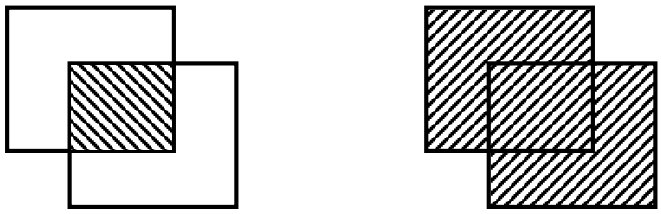


图 2.4: 交并比等于重叠面积除以覆盖面积

后处理操作的示例如图 2.5所示。其中绿色矩形框是模型的预测结果，左上角的值是该预测框的概率，红色矩形框是真实的目标框。在 NMS 操作前，网络模型给出了大

中国知网 https://www.cnki.net

量的预测框结果。观察概率可以发现，在不存在鱼的位置，预测框的概率几乎为 0；在存在鱼的位置，预测框的概率很高且分布更加密集。NMS 操作之后，密集的预测框被抑制，预测框的总数大大减少。进而经过概率阈值 0.5 和最大框数目的筛选过滤，最终的预测框能够与真实框一一对应，且类别概率很高，高达 0.99 和 1.00。

2.2.4 mAP 评价指标

目标检测任务的评价指标是 mAP（mean Average Precision），针对多类别场景，每个类别先计算出各自的 AP 指标，再取平均得到 mAP。只关注“鱼”这一个类别时，则省掉了最后的平均操作，相当于只计算了一个 AP 指标。

表 2.4: 二分类任务中预测值与真实值的四种情况

	预测正	预测负
实际正	TP (True Positive)	FN (False Negative)
实际负	FP (False Positive)	TN (True Negative)

类似二分类任务，如表 2.4，预测框的评测也有 True Positive 等概念，它们的解释如下：

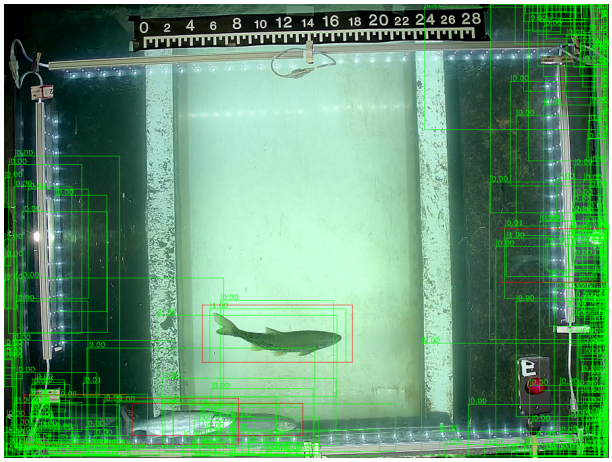
- TP。在有真实框的目标位置，模型给出了预测框。由于预测框与真实框不可能也没必要完全重合，所以用它们的交并比来衡量它们的接近程度。设定一个交并比阈值，一般取 0.5，当交并比大于该阈值，即认为该预测是 TP。需要注意的是，同一个真实框可能对应了多个交并比较大的预测框，在这种情况下，只有与真实框交并比最大的那个预测框才认为是 TP，其余是 FP。
- FN。在有真实框的目标位置，模型未给出预测框，即漏检。召回率 Recall = TP/(TP+FN)，漏检会导致召回率下降。
- FP。在无真实框的背景位置，模型给出了预测框，即误检。精确率 Precision = TP/(TP + FP)，误检会导致精确率下降。
- TN。在无真实框的背景位置，模型未给出预测框。

当模型后处理操作的概率阈值变化时，计算出来的精确率和召回率也会发生变化。一般来说，概率阈值减小，则精确率降低、召回率提高。为了全面关注模型在不同概率阈值下的性能，AP 指标获取所有的 (Precision, Recall) 点对，过程如算法1所示。在计算

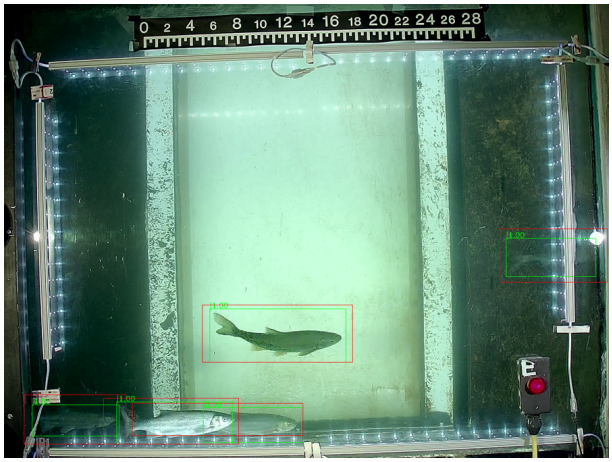
中国知网 https://www.cnki.net



(a) NMS 操作前



(b) NMS 操作后



(c) 最终结果

图 2.5: 后处理操作示例

中国知网 https://www.cnki.net

精确率和召回率时，采用了简化的方法，Precision $=$ TP$/N$，Recall $=$ TP$/M$，其中 N 是当前预测的总数，M 是真实框的总数，显而易见 M 是常数。

算法 1 获取 PR 点对

输入: 真实框集合 T，预测框集合 D，交并比阈值 t

输出: 点对 $P = \{(p_1, r_1), (p_2, r_2), \cdots\}$

初始化 TP $= 0, N = 0, M = |T|, P = \{\}$
在交并比阈值 t 的条件下，判断每个预测框是否是 TP，以便查询
for all 按预测框概率从大到小依次取出 $D_i \in D$ **do**
    if D_i 是 TP **then**
        TP $\leftarrow$ TP $+ 1$
    end if
    N $\leftarrow$ N $+ 1$
    $p \leftarrow$ TP$/N$
    $r \leftarrow$ TP$/M$
    $P \leftarrow P \cup \{(p, r)\}$
end for
return P

之后作出 Precision-Recall 曲线，如图 2.6所示，它与坐标轴围成的面积即 AP 指标值。面积的计算有不同的方式[51]，本章采用全部点插值法，另外采用交并比阈值 0.5 来判断预测框是否属于 TP。

2.3 结果与分析

2.3.1 硬件与软件环境

本章用到的硬件与软件环境如表 2.5所示。后续章节中的实验环境与此一致。

2.3.2 不同方法的 AP 指标对比

从表 2.3看到，MHK 数据集中不含鱼的图像占一半以上。而从正负样本平衡的角度讲，检测任务从不缺少负样本。一张图像中只有真实框的部分是正样本，其余部分均可视为负样本，负样本是远远多于正样本的。不含鱼的图像只能提供负样本，因此对模型

中国知网 https://www.cnki.net

表 2.5: 硬件与软件环境

硬件环境	软件环境
Intel(R) Xeon(R) CPU E5-2660 v4	Ubuntu 16.04.7 LTS
NVIDIA TITAN X (Pascal)	Anaconda 4.8.2
	PyTorch 1.1.0
	mmdet 1.1.0

的训练作用不大。基于这个原因，将训练集中 18123 张有鱼图像加上随机抽取的 1877 张无鱼图像，组合为一个 20000 张图像的新训练集。测试集不做更改。

训练 Faster RCNN 模型，共 12 个 epoch（所有样本遍历一次叫做一个 epoch）。后处理阶段的参数是，NMS 阈值为 0.5，概率阈值为 0，最大预测框数目为 100。结果汇总在表 2.6中。

表 2.6: 不同方法的 AP 指标 (%)

方法	评测	整体	Voith Hydro	Wells Dam	Igiugig
(a) 原论文[20]	测试集	53.92	54.74	55.75	45.07
(b) 不采用数据增强	训练集	98.73	97.98	99.48	93.54
	测试集	56.40	58.18	66.03	33.86
(c) 采用数据增强	训练集	92.12	88.57	94.79	80.02
	测试集	**65.83**	68.01	71.81	38.14
(d) 只评测有鱼的图像	训练集	92.46	88.69	94.80	85.65
	测试集	69.58	69.81	72.24	**56.66**

方法 (a) 是 MHK 数据集论文中的结果，采用单阶段目标检测模型 YOLOv3[32]。

方法 (b) 和方法 (c) 分别是数据增强前后的结果。不采用数据增强时，训练集上的 AP 指标达到了恐怖的 98.73%，但测试集上的 AP 指标只有 56.40%，这是严重的过拟合现象。经过数据增强，模型在训练集上的 AP 指标降低到了 92.12%，而在测试集上的 AP 指标提高到了 65.83%。原因是，数据增强提高了训练数据的多样性，使训练出来的模型泛化性更强，训练集和测试集上的性能差距缩小。具体地，主要是召回率的提升带来了 AP 指标的提升，如表 2.7和图 2.6所示。然而，测试集的 AP 指标仍比训练集差了

中国知网 https://www.cnki.net

25%，原因是：

- 虽然图像的数目不少，但都是视频帧，雷同现象比较严重，所以多样性并不高。在这一点上，MHK 数据集远远比不上非视频类的数据集，比如 VOC[52] 和 COCO[53] 两个通用的数据集。
- 由于水下场景的特殊性，鱼有时会淹没在背景中，用肉眼都很难分辨，但仍有真实框的标注，也就是说任务的难度过大。而训练集有强制的监督信息，所以效果要好的多。但这样的监督信息并不是很合理，例如，用混杂猫和狗的训练数据来训练猫分类器，最终这个猫分类器会将狗也识别为猫。因此，不能归咎为目标检测模型没训练好，而是应该用视频的时间上下文信息来弥补这些缺陷，本文的第三章就是做这样的工作。

表 2.7: 数据增强前后的最终召回率 (%)

方法	评测	整体	Voith Hydro	Wells Dam	Igiugig
不采用数据增强	训练集	99.37	99.10	99.70	96.52
	测试集	82.90	78.32	90.07	78.13
采用数据增强	训练集	98.07	97.82	98.48	93.26
	测试集	**88.53**	86.42	92.01	84.09

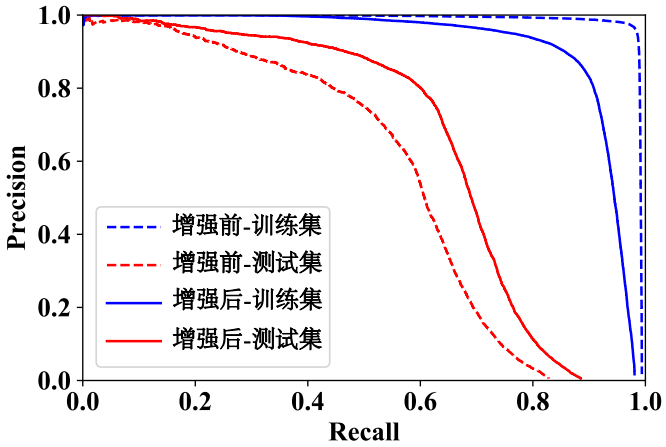


图 2.6: 数据增强前后的 Precision-Recall 曲线

方法 (c) 与方法 (a) 相比，在 Voith Hydro 和 Wells Dam 场景上 AP 指标都获得了 15% 左右的提升，这说明了双阶段模型 Faster RCNN 与单阶段模型 YOLOv3 相比具有精度

中国知网 https://www.cnki.net

上的优势，更高的精度有利于第三章的轨迹关联过程。但在 Igiugig 场景，AP 指标却有一些下降，这是因为 Igiugig 场景非常极端，几乎全是背景图像，有效训练图像只占三个场景总数的 4.5%，所以模型对它的关注度较低；另外，Igiugig 场景的清晰度非常差，难度很高。实际上，这三个场景的差异较大，并不适合用同一个检测模型。在后续的轨迹关联中，仅利用了 Wells Dam 场景的数据，因此这里不做进一步讨论。

方法 (d) 与方法 (c) 相比，只评测了包含鱼的图像。换句话说，强制去掉了大量的误检错误，相对提高了精确率。训练集大多数包含鱼，所以指标变化不大。而在测试集上，Igiugig 场景的 AP 指标从 38.14% 提升到了 56.66%，这是因为不包含鱼的图像占比很大，达 97.6%。

2.3.3 错误案例分析

检测模型的一些错误案例如图 2.7所示，其中红色框是真实的标注框，绿色框是模型的预测框，左上角是该预测结果的概率。

漏检的主要原因有两个：

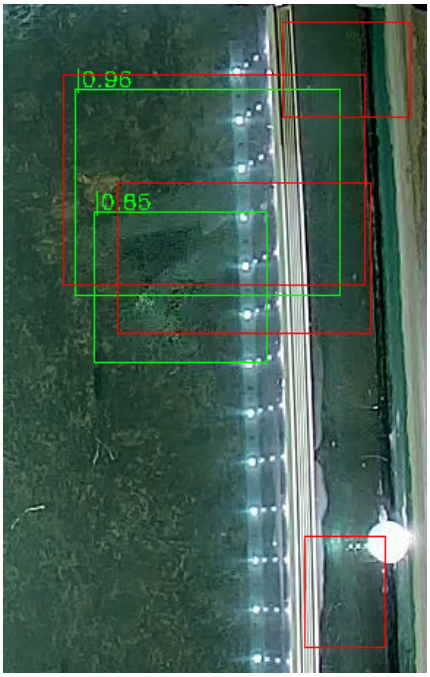
- 真实框的位置很难看出来存在鱼，比如 (a) (d) (e) (h) 中。数据集在标注的时候参考了视频的前后帧，但仅依据单帧信息无法确定这些位置是否存在鱼。
- 几条鱼靠的非常近，重叠现象严重，比如 (b) (d) 中。这种情况下，多条鱼的框几乎重合，交并比非常高，但由于检测模型需要 NMS 操作，即使给出了多个预测框，最后也只会保留一个概率最高的。这一点是检测模型的固有缺陷。

误检的主要原因有两个：

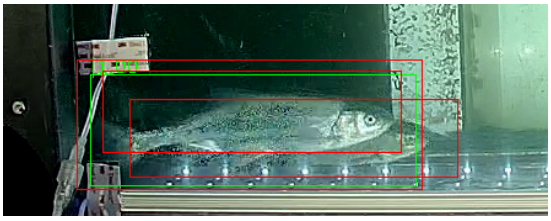
- 预测框的位置有较为明显的非背景特征，比如 (d) (e) (f) (g) 中。因为图像质量太低，人眼也无法分辨。有些情形能够依据视频前后帧判断是预测错误，同时也不排除有些情形是标注错误。
- 几条鱼靠的较近，但重叠现象不高，比如 (c) (d) (e) 中。这种情况下，预测框的边界难以确定，往往会生成大量形状各异的预测框，比如鱼头位置一个框、鱼身位置一个框，NMS 并不能解决这种错误。

总的来看，图像质量过低、鱼类密集是检测模型发生错误的两大因素。

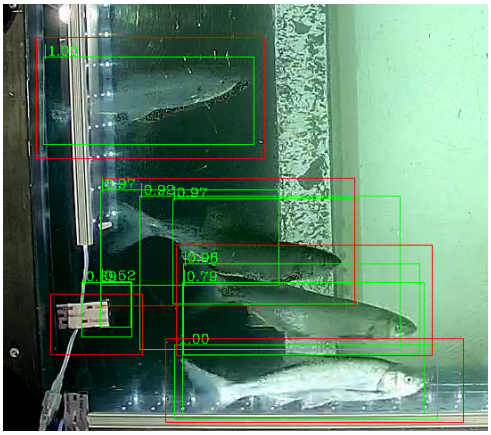
中国知网 https://www.cnki.net



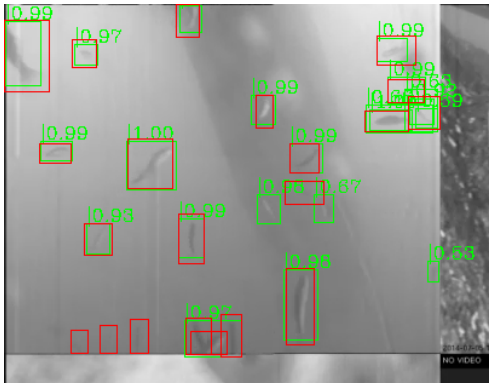
(a) 漏检



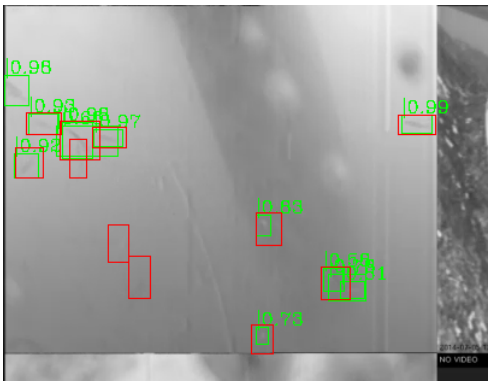
(b) 漏检



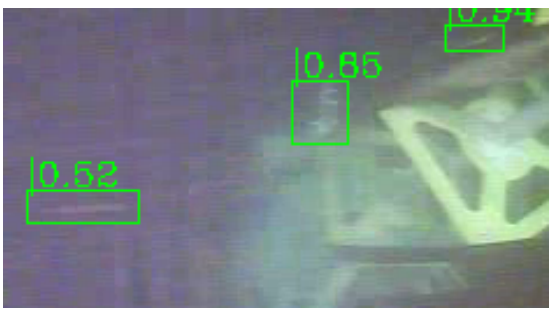
(c) 误检



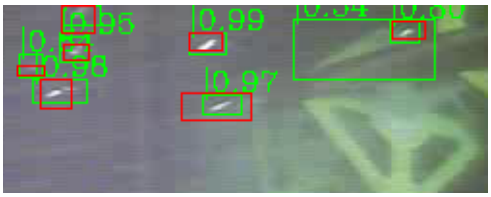
(d) 漏检 + 误检



(e) 漏检 + 误检



(f) 误检



(g) 误检



(h) 漏检

图 2.7: 检测模型错误案例

中国知网 https://www.cnki.net

2.4 小结

本章讲述了如何在 MHK 水下鱼类数据集上利用目标检测模型 Faster RCNN 完成鱼类检测任务，着重介绍了数据增强、网络结构、模型后处理的内容，并可视化分析了一些典型的错误案例。测试集上的 AP 指标从 MHK 论文[20] 中的 53.92% 提高到了 65.83%。下一章将利用这些检测结果串联成鱼类的游动轨迹。

中国知网 https://www.cnki.net

3 基于检测结果的轨迹关联

利用目标检测模型，能够为视频的每一帧给出鱼类的预测框，但帧与帧之间预测框的关系是不清楚的。需要将这些预测框关联起来，以确定哪些框构成了同一条鱼的游动轨迹。这里存在一些问题，比如，如何确定某个框是某条鱼游动轨迹的起始框或者终止框？由于视频质量较低，且存在运动模糊现象，目标检测模型的结果并不完全可靠，那么如何减小检测错误的影响？这些问题需要利用视频的时间上下文信息来解决。

假设连续两帧的预测框集合为 A 和 B，集合大小分别是 m 和 n。对于每两个预测框 $a_i \in A$ 以及 $b_j \in B$，计算它们的关联度 r_{ij}（计算方法之后给出），由此得到大小 $m \times n$ 的关联度矩阵 R。这样一来，问题转化为，如何计算关联度以及如何从关联度矩阵中找到预测框的匹配关系。一旦获得预测框的匹配关系，一些连续匹配的预测框就形成了轨迹段。需要注意的是，目标检测模型或多或少会出现误检和漏检的情况，关联过程并没有纠正这些错误，因此还要对轨迹段做一些针对性的处理，最终获得鱼类个体的游动轨迹。

综上所述，本章提出的轨迹关联方法从以下三个方面来阐述：

- 如何计算两个预测框的关联度；
- 如何利用关联度进行匹配；
- 如何对轨迹结果进行优化。

3.1 关联度的计算

两个预测框在空间和时间上越接近，则它们的关联度越高，从这个角度出发构造关联度。

交并比。基于运动目标的运动连续性，如果 a 和 b 是同一条鱼在连续两帧中的预测框，那么它们在大小、形状、空间位置上均比较接近。交并比是对这种接近程度的一种很好的度量方式：

$$r_{\text{iou}} = \frac{|a \cap b|}{|a \cup b|} \tag{3-1}$$

其中 $|a \cap b|$ 是两个矩形框重叠区域的面积，$|a \cup b|$ 是两个矩形框覆盖区域的面积，如图 2.4所示。交并比 r_{iou} 介于 0~1 之间，这个值越大，a 和 b 两个框的关系越接近，

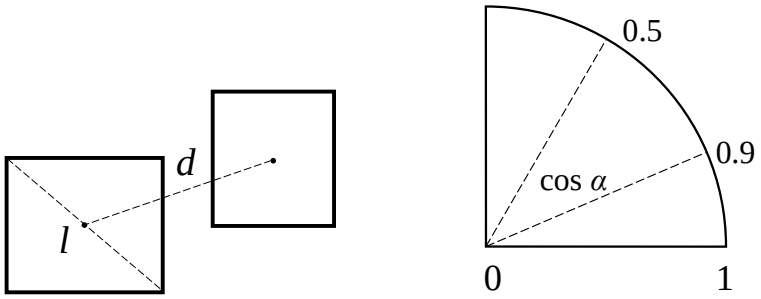
中国知网 https://www.cnki.net

因此越有把握认为它们属于同一条鱼的轨迹。交并比是 SORT 算法[24] 中唯一的关系度量。

中心距离关联度。如果两个矩形框没有重叠，那么它们的交并比为 0，得出结论是这两个矩形框完全无关。但在一些情形中，比如鱼游动速度过快或者视频帧率较低的时候，这样的结论是不正确的。为了弥补这个缺陷，利用两个矩形框的中心距离来构造一种关联度的计算方式：

$$r_{\text{dis}} = \max\left(0, 1 - \frac{d}{\alpha \cdot l}\right) \tag{3-2}$$

其中 d 是两个矩形框的中心距离，l 是前一帧中的矩形框的对角线长，如图 3.1(a) 所示。α 用来调节对距离的容忍程度，实际测试后取 $\alpha = 1.5$，即当 $d \geq 1.5l$ 时，$r_{\text{dis}} = 0$。中心距离关联度是对交并比的一个补充。



(a) 中心距离关联度　　(b) 概率相似度

图 3.1: 中心距离关联度和概率相似度计算示例

概率相似度。前面两个因素仅仅考虑了两个矩形框的位置关系，实际上目标检测模型除了给出预测框的坐标位置，也给出了这个预测框中存在鱼的概率，这个概率衡量了这个预测结果的置信度。从图像感知的角度来看，前后两帧中同一条鱼的外形是相近的，那么同一个检测模型给出的两个预测框对应的概率理应是相近的。依据这一点，需要衡量概率值的接近程度，可以构造余弦相似度来计算：

$$r_{\text{sim}} = p_a \cdot p_b + \sqrt{1 - p_a^2} \cdot \sqrt{1 - p_b^2} \tag{3-3}$$

其中 p_a 和 p_b 分别代表两个预测框中存在鱼的概率。与交并比 r_{iou} 和中心距离关联度 r_{dis} 一样，概率相似度 r_{sim} 也是介于 0~1 之间，且这个值越大，两个框的关系越接近。图 3.1(b) 展示了概率相似度的计算方式，实际上是两个单位向量的夹角的余弦值。概率相似度的作用类似于 DeepSORT 算法[25] 中的外观模型。

中国知网 https://www.cnki.net

最终的关联度综合了上述的三个因素，如式 3-4。交并比 r_{iou} 和中心距离关联度 r_{dis} 考虑的都是矩形框的位置关系，因此它们是相加关系。概率相似度 r_{sim} 与前两者是相乘关系。这三个因素是可选的，之后也会用到式 3-5、式 3-6、式 3-7几种形式。

$$r_1 = (r_{\text{iou}} + r_{\text{dis}}) \cdot r_{\text{sim}} \tag{3-4}$$

$$r_2 = r_{\text{iou}} \tag{3-5}$$

$$r_3 = r_{\text{iou}} + r_{\text{dis}} \tag{3-6}$$

$$r_4 = r_{\text{iou}} \cdot r_{\text{sim}} \tag{3-7}$$

3.2 基于关联度的匹配

对于分别具有 m 和 n 个预测框的连续两帧，用上一节的方式计算两两关联度，能够得到大小 $m \times n$ 的关联度矩阵 R。从关联度矩阵中找匹配关系的目标任务及约束条件可以描述为：

- 取出一些元素，使这些元素的总和尽可能大；
- 在取出的元素中，不能有多于一个元素位于同一行或同一列。

具体地，取出 r_{ij} 意味着将前一帧的第 i 个预测框和后一帧的第 j 个预测框绑定在一起。

这种找匹配关系的问题可以用二分图的形式更直观地表示出来，如图 3.2所示。二分图的左右节点分别是前后两帧的预测框，边的权重是预测框的关联度，选取某条边意味着将这条边关联的两个预测框绑定在一起。目标任务及约束条件可以描述为：

- 选择一些边，使这些边的权重总和尽可能大；
- 在选择的边中，不能有多条边共用一个节点。

在匹配方法确定之后，不断地对视频中的连续帧应用关联度计算和匹配方法，能够生成一些轨迹段。在图 3.2中，连续三帧图像分别有四个、三个、四个预测框，若经过匹配之后选取的边用红色加粗表示，最终形成了三个轨迹段 $a_1 - b_1 - c_4$，$a_2 - b_3 - c_3$ 以及 $a_4 - b_2 - c_2$。用二分图的视角来看，未匹配成功的右节点成为了轨迹段的起始，未匹配成功的左节点成为了轨迹段的终止，这解答了如何处理新旧目标更迭的问题。

3.2.1 匈牙利匹配算法

匈牙利算法广泛应用在任务指派和图匹配等问题中，它能够从二分图中得到最大权匹配，完全适用于检测框关联度匹配的任务[24, 25, 28]。需要说明的是，最早提出的匈牙利

中国知网 https://www.cnki.net

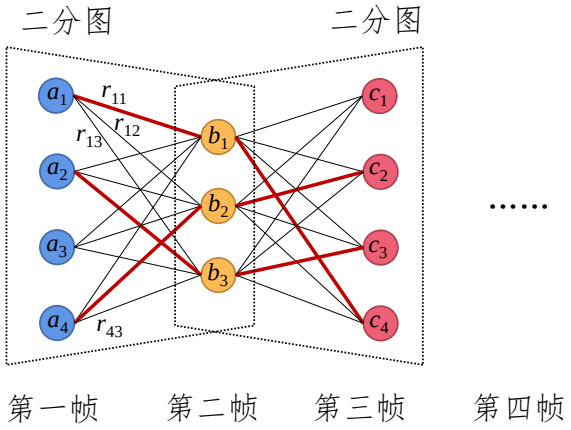


图 3.2: 连续多帧预测框的二分图匹配

算法并未考虑边的权重，即认为所有边的权重都是 1，后来又有许多学者对其进行推广和完善。

匈牙利算法中的一个重要的概念是增广路径。在不考虑边权的最初版本的匈牙利算法中，如果一条路径交替经过左右节点，左 − 右 −···− 左 − 右，且当前时刻除了第一个左节点与最后一个右节点是未匹配状态之外，其余的中间节点均处于已匹配状态，那么这条路径叫做增广路径。增广路径的一大性质是，沿着增广路径调整匹配关系，能够让匹配关系增加一对。例如，在图 3.2中，假设已有一组匹配关系 $a_1 - b_3$，现找到一条增广路径 $a_2 - b_3 - a_1 - b_1$，那么断开匹配关系 $a_1 - b_3$，新增匹配关系 $a_2 - b_3$ 与 $a_1 - b_1$，从而使得匹配关系从 1 对增加到了 2 对。在最大权匹配的匈牙利算法中，除了边的权重之外，为每个节点添加了一个顶标值，用来辅助寻找最大权匹配。顶标值在算法的运行过程中是会变化的。另外，定义边的 z 值为左右节点顶标值之和减去边的权重，$z_{ij} = x_i + y_j - R_{ij}$。当 $z_{ij} = 0$ 时，才认为这条边是增广路径的一条合法边。

匈牙利算法的大致流程如算法2所示。为了实现方便，不妨保证输入的二分图满足 $m \leq n$；当实际的 $m > n$ 时，可以先将二分图的左右节点互换，再应用算法。寻找增广路径的时间复杂度是 $O(mn)$，每个节点最多找 m 次，共 m 个节点，因此匈牙利算法的时间复杂度为 $O(m^3n)$。

算法 2 匈牙利匹配算法

输入: $m \times n$ 的二分图，边的权重矩阵是 R，保证 $m \leq n$

输出: 匹配关系对 $P = \{(i_{p1}, j_{p1}), (i_{p2}, j_{p2}), \cdots\}$

1: 初始化左节点的顶标值为 $\max_j R_{ij}$

2: 初始化右节点的顶标值为 0

中国知网 https://www.cnki.net

3: **for** $k = 1$ 至 m **do**
4: **while** 从左边第 k 个节点出发寻找增广路径，但没找到 **do**
5: $z_{\min} \leftarrow$ 已遍历路径上的最小 z 值
6: 所有已遍历路径上左节点的顶标值增大 $z_{\min}$
7: 所有已遍历路径上右节点的顶标值减小 $z_{\min}$
8: **end while**
9: 依据增广路径调整左右节点的匹配关系，使匹配关系增加一对
10: **end for**
11: 初始化空集合 $P = \{\}$
12: **for all** $(i, j) \in$ 匹配关系对 **do**
13: **if** $R_{ij} > 0$ **then**
14: $P \leftarrow P \cup \{(i, j)\}$
15: **end if**
16: **end for**
17: **return** P

3.2.2 贪心匹配算法

贪心匹配算法的流程是：

(1) 从关联度矩阵 R 中取出最大的元素，并划掉此元素所在的行与列，划掉的行与列不能再被选取；

(2) 在剩余的行列中重复执行 (1)，直至已经没有元素可取或者剩余的元素全部为 0。

在具体实现时，贪心匹配算法如算法3所示，首先对所有元素进行了一次排序。贪心匹配算法的时间复杂度由排序算法主导，是 $O(mn(\log m + \log n))$。与匈牙利匹配算法相比，贪心匹配算法不能保证获得全局最优解。但在计算效率方面，贪心匹配算法更有优势。

算法 3 贪心匹配算法

输入： $m \times n$ 的关联度矩阵 R

输出： 匹配关系对 $P = \{(i_{p1}, j_{p1}), (i_{p2}, j_{p2}), \cdots\}$

1: 将 R 中的所有元素从大到小排序，得到元素的下标顺序 $I = [(i_1, j_1), (i_2, j_2), \cdots]$
2: 初始化空集合 $V_i = \{\}, V_j = \{\}, P = \{\}$
3: **for** $k = 1$ 至 $m \times n$ **do**

中国知网 https://www.cnki.net

$(i,j) \leftarrow I_k$
if $R_{ij} <= 0$ **then**
    break
end if
if $i \notin V_i$ 且 $j \notin V_j$ **then**
    $V_i \leftarrow V_i \cup \{i\}$
    $V_j \leftarrow V_j \cup \{j\}$
    $P \leftarrow P \cup \{(i,j)\}$
end if
end for
return P

3.3 轨迹关联结果优化

如果要利用上文的匹配方法获得一条鱼的完整轨迹，检测模型必须在所有帧上都正确检测到鱼，并且在匹配过程中不能有其他检测框的干扰。这对一个预测模型来说几乎是不可能的。因此需要对初步获得的轨迹段做一些针对性的后处理，以提高轨迹提取的准确性。

3.3.1 连接相近的轨迹段

检测模型的一个主要错误是漏检，在存在鱼的位置未给出预测框。实际上，由于水下视频质量低及运动模糊等问题，有时很难依据一帧图像判断某个位置是否存在鱼，因此漏检现象是比较常见的。一旦发生漏检，一条真实的完整轨迹会被分成好几段，从而被当作多条鱼，这是不合理的。

弥补漏检错误的方法是连接相近的轨迹段。直观地说，用二分图的视角来看，将所有轨迹段的终止框作为二分图的左节点，将所有轨迹段的起始框作为二分图的右节点，进而应用类似前后两帧匹配的方法。区别在于，这里添加了一个阈值 k。假定某个终止框处于帧 t_1，某个起始框处于帧 t_2，仅当 $1 \leq t_2 - t_1 \leq k+1$ 时，才会在它们之间形成合法边。$k=0$ 意味着什么也不做，而随着 k 的增大，对漏检的容忍程度越来越大。

当连接一些分立的轨迹段时，需要用插值的方法来找回那些漏检的矩形框：

$$c_i = \frac{t_2 - i}{t_2 - t_1} c_{t_1} + \frac{i - t_1}{t_2 - t_1} c_{t_2} \tag{3-8}$$

中国知网 https://www.cnki.net

$$p_i = \frac{p_{t_1} + p_{t_2}}{2} \tag{3-9}$$

其中 $i = t_1 + 1, \ldots, t_2 - 1$。$c$ 代表矩形框左上右下四个坐标 $x_{\min}, y_{\min}, x_{\max}, y_{\max}$，$p$ 是矩形框中存在鱼的概率。

3.3.2 删除较短的轨迹段

检测模型另一个主要错误是误检，在一些背景位置给出了鱼的预测框。在检测模型的后处理阶段，需要设置一个概率阈值，算法会丢弃概率低于该阈值的预测框。如果该概率阈值过小，比如 0.1 或更低，那么检测模型会留下大量的预测框，其中大多数是没把握的，如图 3.3所示。这样会带来两个弊端，(1) 增加匹配过程的计算量；(2) 给匹配过程带来大量的干扰，影响匹配的正确性。因此，该概率阈值实际设置的较高，为 0.5。这样一来，尽管检测模型仍然会产生误检错误（预测框的概率大于 0.5，但不存在鱼），但发生的几率并不大；进一步地，在同一位置连续多帧均产生误检错误的几率更低。依据这一点，减少误检错误的方法是删除较短的轨迹段。设置一个阈值 n，当轨迹段的长度（即跨越的帧数）小于等于 n 时，则丢弃该轨迹段。

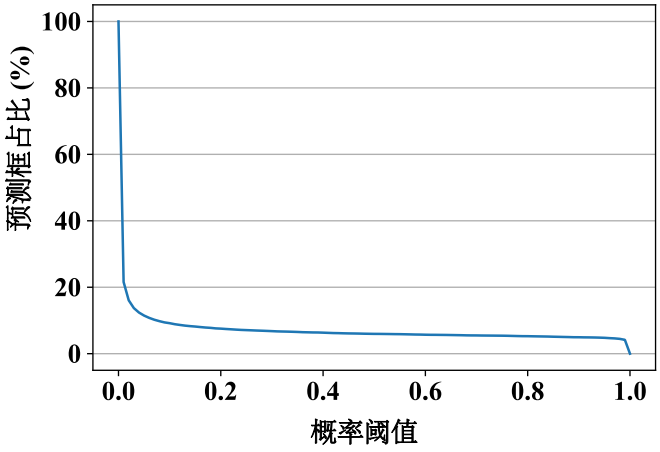


图 3.3: 概率大于某个阈值的预测框数目占比

3.4 结果与分析

为了较好地测试轨迹提取的性能，从 Wells Dam 测试集中截取出一段鱼类活动较多的视频。视频共 150 帧，帧率是 30 fps，分辨率是 1280×960。利用上一章的方法，仅用 Wells Dam 训练集来训练 Faster RCNN 模型。在后处理阶段，NMS 阈值为 0.5，概率阈值为 0.5，最大预测框数目为 100。在该 150 帧测试视频上，模型的 AP 指标为 74.75%。

中国知网 https://www.cnki.net

3.4.1 不同实验设置下的消融实验

为了全面测试轨迹关联方法各部分的作用,在不同实验设置下进行消融实验,表3.1给出了实验结果。关注的指标是目标检测任务的AP指标,AP指标的高低反映了轨迹提取的好坏。不同实验设置中优化操作的参数是固定的:连接操作 $k = 45$,删除操作 $n = 10$。

表 3.1: 不同实验设置下的 AP 指标 (%)

实验设置		(a)	(b)	(c)	(d)	(e)	(f)
关联度计算	交并比		✓	✓	✓	✓	✓
	中心距离			✓			
	概率相似度				✓	✓	✓
匹配算法	贪心		✓	✓	✓		✓
	匈牙利					✓	
优化方法	连接		✓	✓	✓	✓	✓
	删除						✓
AP 指标 (%)		74.75	80.23	79.98	80.81	80.60	**80.94**

实验 (a) 是轨迹关联之前的结果,AP 指标为 74.75%。实验 (b) 是轨迹关联的基本设置,关联度计算只考虑交并比因素,匹配算法采用贪心算法,优化方法采用 $k = 45$ 的连接操作。加上轨迹关联之后,实验 (b) 的 AP 指标从 74.75% 提高到了 80.23%。这是性能提升的主要来源,后续的实验设置带来的是额外的小提升。连接操作能够减少漏检错误,具体的讨论在小节 3.4.2中。

与实验 (b) 相比,实验 (c) 和实验 (d) 的关联度计算分别额外考虑了中心距离和概率相似度因素。实验 (c) 的 AP 指标比实验 (b) 降低了 0.25%,这是因为中心距离关联度的优势在该测试视频的条件下没有体现出来,进一步的实验和具体的讨论在小节 3.4.3中。实验 (d) 的 AP 指标比实验 (b) 提高了 0.58%,这表明对概率相似度的额外关注能够减少一些匹配错误。

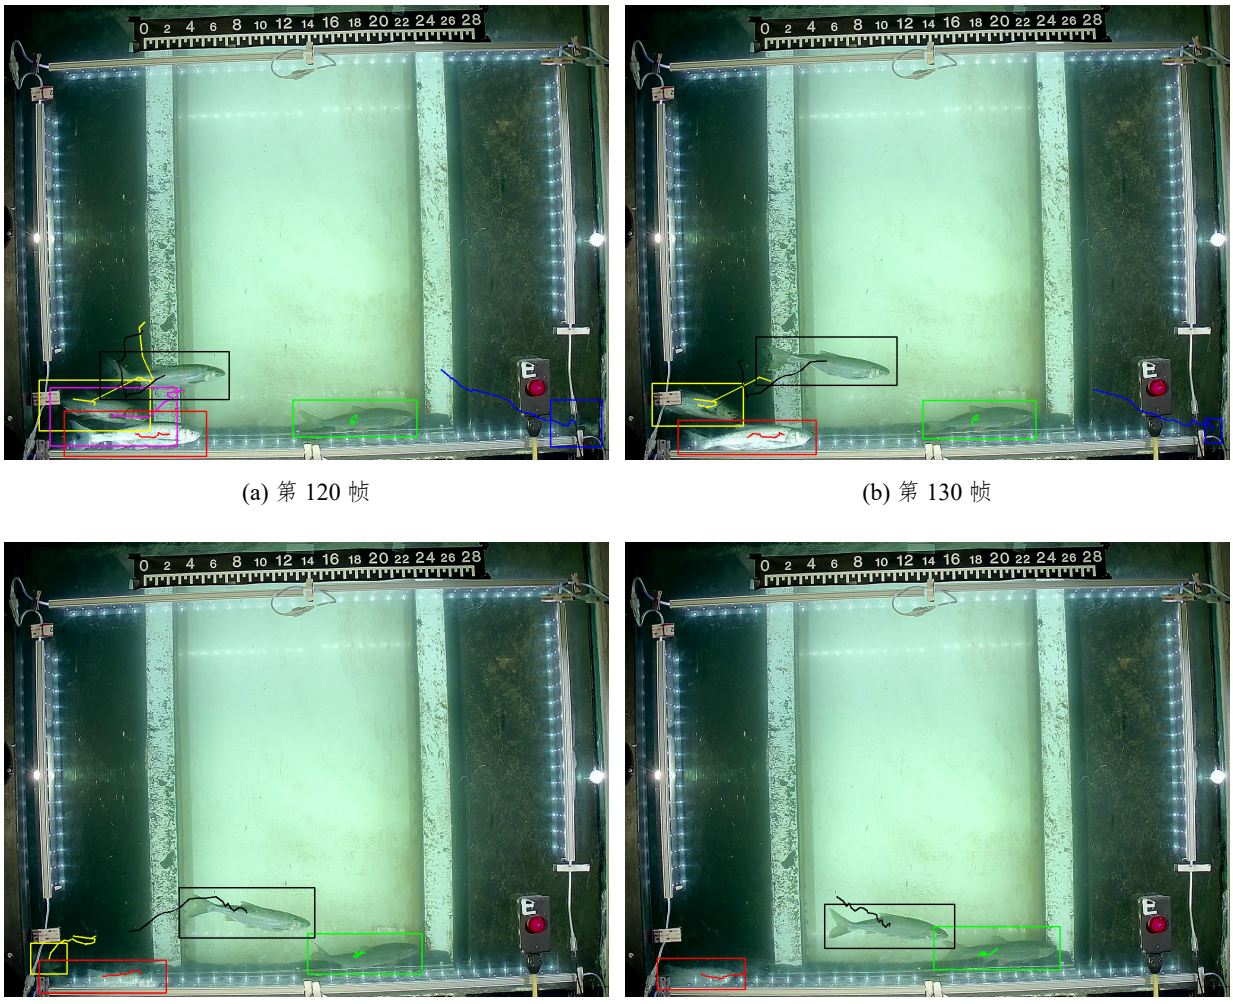
与实验 (d) 相比,实验 (e) 的匹配算法替换成了匈牙利算法,但 AP 指标降低了 0.21%。理论上来讲,匈牙利算法能够获得全局最优解,而贪心算法不能保证获得全局最优解。匈牙利算法效果更差的原因在于,关联度匹配并不是一个严格的数学问题,本章定义的关联度仅仅是一个相对的概念。考虑关联度 $r_1 > r_2 > r_3 > r_4$,其中 $r_2 + r_3 > r_1 + r_4$。而选择 r_2 和 r_3 并不比选择 r_1 和 r_4 更好,也就是可以认为,r_1 这种高关联度对性能的

中国知网 https://www.cnki.net

影响更大，这可以作为贪心算法优于匈牙利算法的一个解释。另外，在算法效率方面，完成这 150 帧视频的匹配，贪心算法用时 40 毫秒，而匈牙利算法用时 200 毫秒。因此，本章的轨迹关联方法更适合用贪心算法作为匹配算法。

与实验 (d) 相比，实验 (f) 额外添加了 $n = 10$ 的删除优化，AP 指标从 80.81% 提高到了 80.94%。删除操作能够减少一些误检错误，具体的讨论在小节 3.4.2中。

采用最佳实验设置 (f)，对测试视频进行轨迹提取操作，结果如图 3.4所示。可以看到，几条鱼的游动轨迹被正确地提取了出来。其中，不同颜色的矩形框代表不同的鱼，中心的连续折线反映了过去 20 帧的运动轨迹。



(a) 第 120 帧 (b) 第 130 帧

(c) 第 140 帧 (d) 第 150 帧

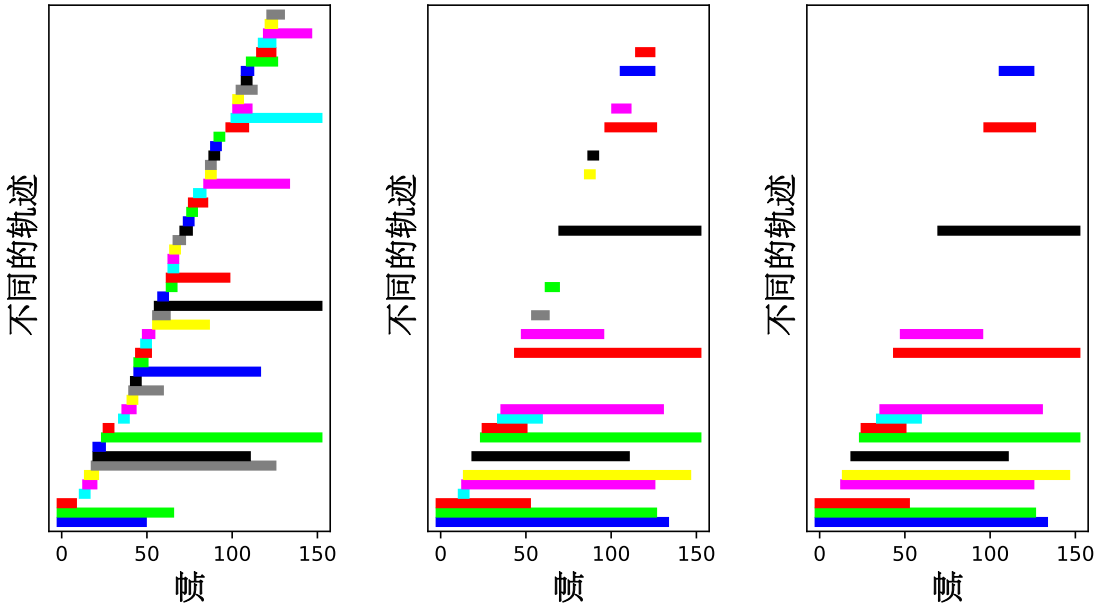
图 3.4: 在不同时间点的轨迹提取结果

中国知网 https://www.cnki.net

3.4.2 连接和删除的影响

图 3.5展示了连接、删除操作前后轨迹结果的变化过程，横轴代表视频时间，不同颜色的横线分别代表某条轨迹跨越了视频的哪些帧。在连接操作前，共有 55 条轨迹段。连接操作能够将多条短的轨迹段连成一条长的轨迹（这里 $k = 45$），轨迹段的数目减少到 22 条。删除操作丢弃了长度不大于 10 的轨迹段，轨迹段的数目进一步减少到 15 条。

图 3.6展示了删除操作前后，AP 指标随连接参数 k 的变化，这里删除操作的 $n = 10$。先讨论连接操作的作用。k 从 0 逐渐增大，AP 指标也随着增大，这是因为检测模型的一些漏检错误被改正了过来，使预测的召回率更高了；当 k 足够大时，继续增大 k 不是一个好的选择，因为更容易带来一些误检，从而让预测的精确率变低，造成 AP 指标的损失。再来讨论删除操作的作用。当 k 很小的时候，大量正确的轨迹段还未连成长的轨迹段，删除操作会错误地将它们丢弃，因此 AP 指标下降了很多；而当 k 是个合适的值时，删除操作会丢弃一些误检错误，给 AP 指标带来一些小提升。结果表明 $k = 45$ 时 AP 指标提升最大。用帧率 30 fps 换算，$k = 45$ 是 1.5 秒，这是一个比较长的间隔。间隔较长的原因是水下场景中检测模型漏检较为严重，有不少时间鱼被淹没在背景中难以发现，如图 2.7所示。



(a) 连接操作前 (b) 连接操作后 (c) 删除操作后

图 3.5: 连接、删除操作前后轨迹结果的变化过程

中国知网 https://www.cnki.net

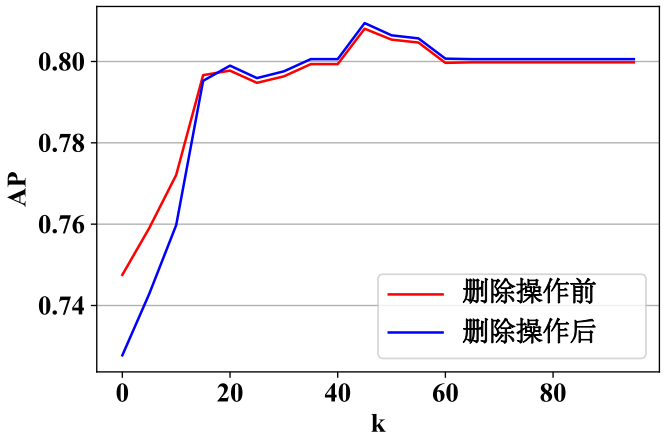


图 3.6: 删除操作前后，AP 指标随连接参数 k 的变化

从以上的结果和分析可以得出结论，连接和删除操作确实能够纠正一些检测模型的漏检和误检错误，从而让 AP 指标获得提升。

3.4.3 中心距离关联度的影响

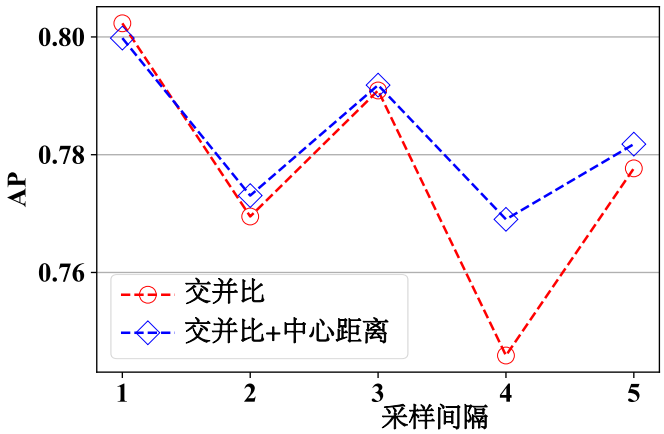


图 3.7: 不同采样间隔下，采用中心距离关联度对 AP 指标的影响

在空间位置关系上，中心距离关联度是对交并比的一个补充。将测试视频隔帧采样，即相当于减小视频帧率，来对比“交并比”与“交并比 + 中心距离”两种实验设置，结果如图 3.7所示。两种实验设置均采用贪心匹配算法，并用连接操作进行优化。为了保证前后一致性，连接操作的阈值设置为 $k = 45/$ 采样间隔（采样间隔为 2 时，代表每两帧采样一帧）。测试视频的初始帧率是 30 fps，这时“交并比 + 中心距离”的 AP 指标比“交并比”的 AP 指标稍微差一点；当采样间隔提升到 2，或者说是视频帧率减小到 15

中国知网 https://www.cnki.net

fps 时，“交并比 + 中心距离”的 AP 指标超过了“交并比”的 AP 指标。这样的结果说明了，在视频帧率较低或者鱼游动速度较快的场景中，额外考虑中心距离关联度，对轨迹提取的准确度是有帮助的。

3.5 小结

本章讲述了关联检测结果、进而生成轨迹的方法，并对关联度计算、匹配算法、优化方法各个组件进行了实验和分析。结果表明，这种关联方法能够正确地获得鱼类游动轨迹，并有效地提升整体的 AP 指标。

综合本章和上一章的方法，能够完成输入视频、输出轨迹信息的流程。下一步是对这些轨迹进行异常判别。

中国知网 https://www.cnki.net

4 基于特征变换的轨迹异常判别

前面两章从视频中提取鱼类游动轨迹的工作的研究对象是MHK水下鱼类视频数据集，但MHK数据集不关注轨迹是否异常。这一章的研究对象是Fish4Knowledge水下鱼类轨迹数据集，采用训练自编码器的方法将轨迹数据变换为固定长度的特征，进而完成轨迹异常判别。

4.1 水下鱼类轨迹数据集

4.1.1 Fish4Knowledge 数据集

Fish4Knowledge 项目[54] 公开了一个水下鱼类轨迹数据集[37]。轨迹数据由一连串的矩形框数据组成，与前两章轨迹提取方法得到的数据一致，并且每条轨迹标注了是否异常，如表 4.1所示。

表 4.1: Fish4Knowledge 轨迹数据形式

数据	解释
x	矩形框最左边的坐标
y	矩形框最上边的坐标
w	矩形框的宽度
h	矩形框的高度
class	1 表示正常，2 表示异常

这些轨迹数据从 93 个短视频中取得，视频的分辨率为 320×240，帧率为 5 fps，拍摄的是珊瑚礁附近的热带鱼。不过，原始视频并没有随着轨迹数据集一起公开，因此无法通过可视化辅助研究。数据集有 3043 条正常轨迹和 59 条异常轨迹。

正常轨迹的行为模式有：在水中自由游动；悬浮在珊瑚上。

异常轨迹的行为模式有：突然潜入珊瑚中；突然改变方向；咬珊瑚，或与浮游生物交互；由于惊吓，在珊瑚中窜来窜去；有攻击性的行为。

官方页面[55] 给出了轨迹的示例，如图 4.1所示，蓝色的折线表示鱼在一段时间内的轨迹。

中国知网 https://www.cnki.net



(a) 正常行为 (b) 异常行为

图 4.1: Fish4Knowledge 轨迹数据示例

4.1.2 数据集分析

Fish4Knowledge 轨迹数据集有以下特点：

- 异常数据占比非常小，只有 $59/3102 = 1.9\%$。这符合现实世界的规律，异常现象发生的概率是很小的，否则也不应该称之为异常。从这个角度来说，异常判别不适合当作一个分类问题。通常分类模型要关注正负样本数目是否平衡，若不平衡则需要做针对性的处理。另一方面，异常数据过少，它们不能代表所有异常情况的分布，若通过监督训练的方法获得模型，那么对于某些不在训练集中的异常样本，该模型的行为是未知的。因此，不同于监督训练的方式，要通过异常点、离群点检测的思路来完成异常轨迹的判别。
- 轨迹数据是时间序列数据，即维度 $t \times d$，其中维度 t 是时间，维度 d 是特征维数，对于 xywh 型的矩形框坐标来说，$d = 4$。时间序列数据可以看作是多个 d 维特征的列表，且列表的长度是不定的。典型的时间序列数据有气温、股价等。对于固定长度的特征，各种机器学习模型均擅长处理，比如决策树、支持向量机、神经网络等。然而对于时间序列数据，RNN（Recurrent Neural Network，循环神经网络）可以天然地处理，但其他模型无法胜任。因此模型的选择非常重要。

4.2 基于自编码器的特征变换

异常点、离群点检测的思想是，建模出正常轨迹数据的分布，用新来的样本与这个分布对比，若差距过大则认为是异常。按照这样的思路，轨迹数据集划分如下：50% 正

中国知网 https://www.cnki.net

常轨迹（数目为 1521）作为训练集，其余 50% 正常轨迹（数目为 1522）与 100% 异常轨迹（数目为 59）作为测试集。

建模数据分布可以用聚类方法来实现，或者说选出若干个正常轨迹样本的代表。聚类的关键在于如何计算两个样本的距离，或者反过来说，两个样本的相似度。对于固定长度的特征，距离的计算是较为直接的，最常见的是欧氏距离。但轨迹数据是长度不定的时间序列数据。因此建模轨迹数据的分布有两条路线：

(1) 寻找一种方法，直接计算两个时间序列数据的距离。这种路线的挑战是，时间序列数据往往具有平移、伸缩、弯曲等特性，如何将这些因素纳入评测标准。Python 语言的 tslearn 包[56] 是面向时间序列分析的机器学习工具包，包括了几种衡量时间序列数据之间的距离的方法。一种是 DTW 距离（Dynamic Time Warping），利用动态规划将原本时间点不匹配的数据对应起来，主要应用在模板匹配、孤立词语音识别任务上。另一种是 k-shape 聚类算法[57]，采用互相关统计来寻找形状相似的序列，具有尺度不变性和漂移不变性。在 tslearn 的实现中，k-shape 算法需要输入长度固定的时间序列数据。然而，鱼类轨迹数据难以归为模板匹配问题，因为它们不像交通道路上的轨迹那样符合一定的规则，并且它们的时间长度也没有特别的限制（Fish4Knowledge 轨迹数据集的长度分布直方图如图 4.2所示，轨迹长度最小是 2，最大是 82）。因此，这些方法不适合处理鱼类轨迹数据。

(2) 先将时间序列数据变换为固定长度的特征向量，再做进一步的处理。变换方式分为两种。一种是人工构造特征，这是文献 [37-39] 的做法。这种方式非常依赖于人工特征的设计，而近年来端到端概念的流行让特征工程融为模型的一部分成为趋势，因此另一种方式是利用网络模型来变换特征。RNN 在每个时间点的输出都是固定长度的特征，那么可以将 RNN 最后一个时间点的输出作为特征变换的结果。新问题是如何训练这个 RNN 网络，在分类任务中利用的是成对的训练数据 (输入数据，分类标签)，但异常检测不能利用分类标签这样的有监督的信息。本节通过训练自编码器网络来解决这个问题，训练数据是 (输入数据，输入数据)，标签即输入数据自身，这是无监督的学习方式。

中国知网 https://www.cnki.net

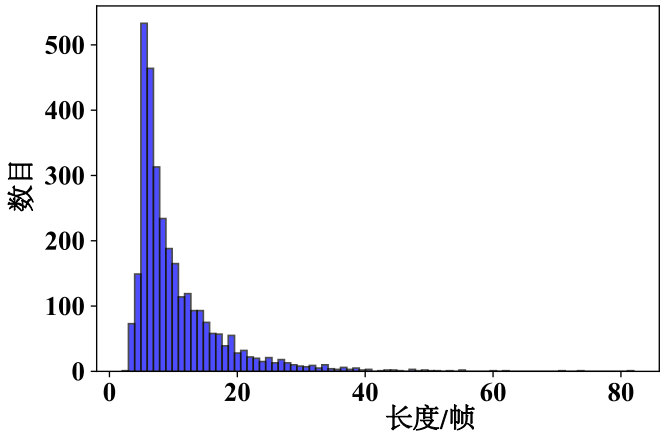


图 4.2: Fish4Knowledge 轨迹数据长度分布

4.2.1 自编码器原理

自编码器的基本原理如图 4.3所示，分为编码器和解码器两部分。编码器对数据的原始表示进行编码，获得隐层表示；解码器利用隐层表示，试图恢复出原始表示。用式子表示：

$$B = \text{Encoder}(A) \tag{4-1}$$

$$A' = \text{Decoder}(B) \tag{4-2}$$

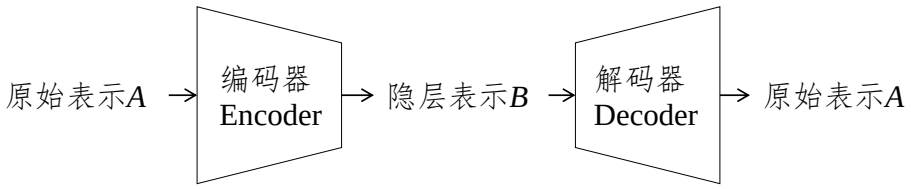


图 4.3: 自编码器框架

在训练中，自编码器的输入数据是 A，标签数据也是 A，这是一种无监督的学习方式。尽管自编码器看起来非常简单，但其思想非常强大，能够灵活地应对不同任务的需要。通常来说，自编码器的目标是在隐层获得数据的高效表示。隐层表示的维度通常远小于原始表示的维度，因此自编码器可以用来对数据降维。其次，对输入数据加一些噪声，构造训练数据对 $(A+\varepsilon, A)$，能够让自编码器学会去噪。另外，构造随机的隐层表示

中国知网 https://www.cnki.net

B，利用解码器能够获得对应的 A，这变为了一个生成模型。对于不同的任务需求，自编码器模型的具体实现方式、训练方式、注意要点也不同。

利用自编码器完成特征变换的目标是，隐层表示能够很好地编码轨迹数据的原始表示，这样才能只利用隐层表示来进行异常判别而不出现偏差。而保证这一点的方式是，如果利用隐层表示能够成功恢复出原始表示，那么隐层表示肯定包含了原始表示的信息。当然，期望原始数据一丝不差地恢复出来，这是不现实的，尤其是针对较为复杂的时间序列数据，那么最终的关键点是如何权衡训练的难度和模型的性能。

4.2.2 GRU 结构

RNN 能够处理变长的时序数据，典型结构如图 4.4所示。x 是 $N \times D$ 的时间序列数据，x_t 是某一时间点的 D 维特征。h 代表 RNN 的隐层表示，h_0 是人为设定的初始值，当前时间点的隐层表示 h_t 由上一时间点的隐层表示 h_{t-1} 和当前时间点的输入 x_t 共同计算得到。$y = h_N$ 是最后一个时间点的输出。

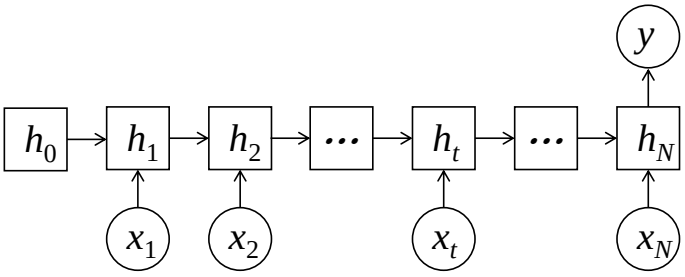


图 4.4: RNN 的循环结构

最简单的 RNN 内部结构如图 4.5(a) 所示，虽然最终的输出 y 能够综合 $x_1 \sim x_N$ 的所有信息，但由于反向传播过程的梯度消失现象，这样的 RNN 并不能学习到输入数据的长距离依赖。LSTM[58]（Long Short-Term Memory）和 GRU[59]（Gated Recurrent Unit）能够解决长距离依赖的问题，内部结构也复杂得多。本节采用 GRU 作为 RNN 模块。

GRU 实际上是 LSTM 的简化版本，它的内部结构如图 4.5(b) 所示。计算过程是：

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t] + b_z) \tag{4-3}$$

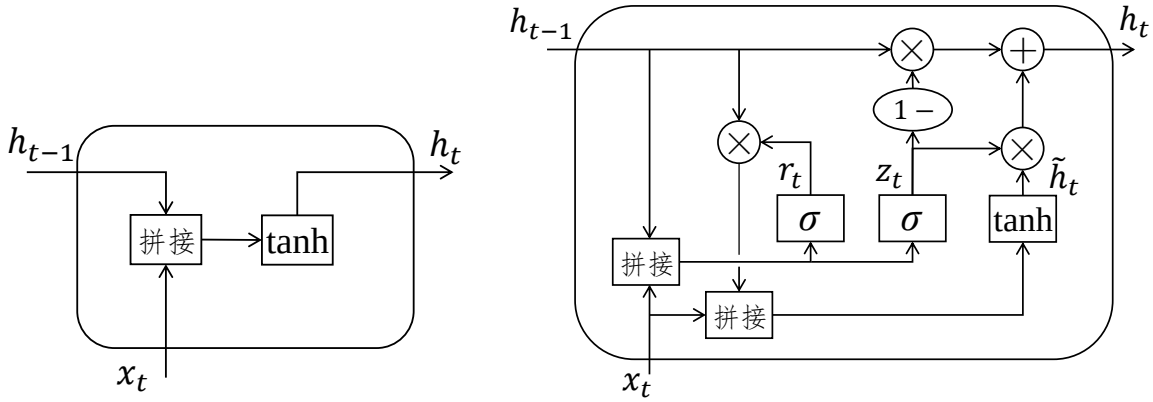
$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t] + b_r) \tag{4-4}$$

$$\tilde{h}_t = \tanh(W_h \cdot [r_t \odot h_{t-1}, x_t] + b_h) \tag{4-5}$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \tag{4-6}$$

中国知网 https://www.cnki.net

其中 $\cdot$ 代表矩阵乘法，$\odot$ 代表对应元素乘法，$[h_{t-1}, x_t]$ 代表拼接操作，$\sigma(\cdot)$ 代表 Sigmoid 函数。



(a) 简单 RNN (b) GRU

图 4.5: RNN 的内部结构

GRU 引入了两个门，一个是重置门 r_t（reset gate），另一个是更新门 z_t（update gate）。h 不仅是 GRU 的隐层表示，也可以理解为 GRU 的状态或记忆值。重置门 r_t 作用在旧记忆值 h_{t-1} 上，类似于一个特征选择的过程，之后经过 tanh 得到候选的记忆值 $\tilde{h}_t$。更新门 z_t 对旧记忆值 h_{t-1} 和候选记忆值 $\tilde{h}_t$ 做一次加权和，得到新记忆值 h_t。z_t 接近 0 时，旧记忆保留了很多，实现了重要信息的记忆；z_t 接近 1 时，则旧记忆丢弃了很多，实现了不重要信息的遗忘。通过这样的门控机制，GRU 就有能力学习到数据的长距离依赖。

4.2.3 自编码器网络结构设计

采用 GRU 作为处理时间序列数据的模块，自编码器网络的结构如图 4.6所示。编码器是一个 GRU 网络，解码器是另一个 GRU 网络，任务是完成 $A \to B \to A'$ 的转换。

虚线框内展示了时间点 t 时的数据流动情况。编码器部分是一个普通的 GRU 网络，没有其他额外的操作，初始值 h_0 为零向量。编码器最后一个时间点的输出 h_N 是期望得到的编码特征 B。而解码器部分则复杂了许多，原因是为了更好地指导解码器的训练，降低解码器学习的难度。解码器 GRU 网络的初始值设置为 $h_0 = B$。

设计一个可行的网络结构需要关注网络模型中各部分数据的表达能力。原始轨迹数据是坐标形式，为了凸显轨迹的运动特征，首先将 xywh 型的轨迹数据转换成 dxdy 型的数据，如式 4-7和式 4-8所示。另外，对输入数据做标准化处理，让其分布呈现均值为 0，

中国知网 https://www.cnki.net

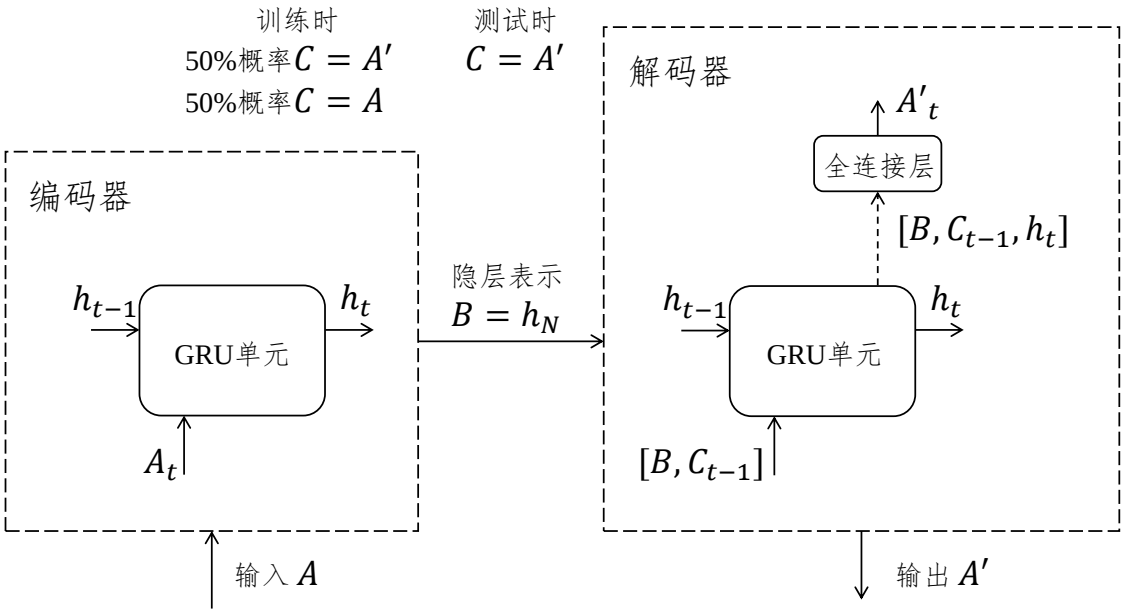


图 4.6: 自编码器网络结构

标准差为 1 的状态，如式 4-9所示，其中 mean$(\cdot)$ 和 std$(\cdot)$ 分别计算全部数据 a 的均值和标准差。从数据流动来看，这样的输入数据经过编码器，输出值的范围取决于 tanh，即 $[-1,1]$，经过解码器后数值范围仍然是 $[-1,1]$。之后经过一个全连接层，将 $[-1,1]$ 的数据再做一次变换，使 A' 在表达能力上能够与 A 匹配的上。

$$dx_t = x_t - x_{t-1} + \frac{w_t - w_{t-1}}{2} \tag{4-7}$$

$$dy_t = y_t - y_{t-1} + \frac{h_t - h_{t-1}}{2} \tag{4-8}$$

$$\forall i, a_i = \frac{a_i - \text{mean}(a)}{\text{std}(a)} \tag{4-9}$$

除此之外，解码器的 GRU 网络和全连接层的输入，均采用多个数据拼接的输入形式，这是为了提供足够的信息。编码器将时间序列数据转换为固定长度的特征，而解码器反过来，将固定长度的特征转换为时间序列数据，解码器的任务难度高得多。辅助信息包括隐层表示 B 和上一时间点的输出 C 两个部分。C 在训练和测试过程中的表现不同，在测试过程中 $C = A'$，而在训练过程中有 50% 的概率 $C = A$（C_0 设定为零向量）。这种设置叫做 Teacher Forcing 机制[60]，50% 是设定的一个比例。如果没有 Teacher Forcing 机制，解码器是这样工作的：利用 B 获得第一个时间点的输出 A'_1，再利用 A'_1 获得第二个时间点的输出 A'_2，以此类推；最终将 A' 与 A 进行对比。这个思路看似很正

中国知网 https://www.cnki.net

常，但考虑这种情况：如果网络的效果很差（比如刚开始训练时），第一个输出 A_1' 与期望输出 A_1 差距非常大，那么下一步利用 A_1' 期望获得 A_2 则毫无意义，形成一步错、步步皆错的局面。Teacher Forcing 机制的引入正是为了让解码器获得更多的指导信息，让网络参数得到有效的训练。

从实践角度讲，可以在编码器 GRU 网络的出口、解码器 GRU 网络的入口等位置添加一些额外的 DropOut 层、全连接层等结构，以提升网络模型的泛化能力和提取特征的能力。但 Fish4Knowledge 轨迹数据集数目不多、数据形式不复杂，且在网络结构设计过程中，显式地进行了一些数据变换的工作，因此图 4.6的网络模型能够很好地完成特征变换的工作。

4.2.4 结果与分析

利用本节的方法训练自编码器网络，50% 的正常轨迹样本作为训练样本，其余作为测试样本。所有数据都预处理为 dxdy 型，编码器和解码器 GRU 网络的隐层大小设置为 128，即最终编码成的特征是 128 维。模型在训练集上训练了 200 个 epoch，优化器采用 Adam，初始学习率为 0.001。

需要注意的是，在训练时，编码器-解码器这样的组合是必要的，因为需要原始数据作为标签来推动模型参数的更新。在训练完成之后，对于轨迹数据特征变换任务，仅利用编码器结构即可。利用训练好的编码器，将所有轨迹数据转换为 128 维特征，并利用 t-SNE 方法[61] 可视化出来，结果如图 4.7所示。

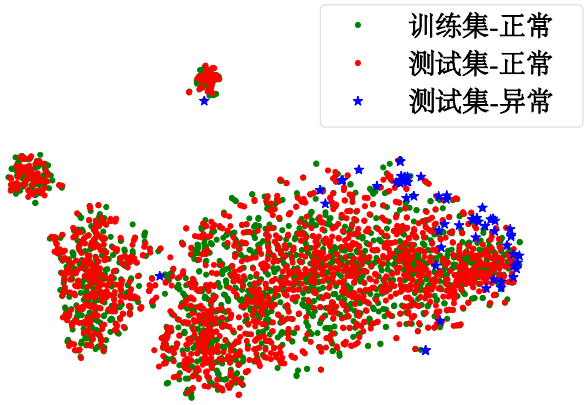


图 4.7: 轨迹特征数据的 t-SNE 可视化

t-SNE（t-distributed stochastic neighbor embedding）是一种非线性的降维算法，通常

中国知网 https://www.cnki.net

的应用是将高维数据降维到 2 维或 3 维，便于计算机可视化作图。在图 4.7中，绿色点和红色点分别代表训练集和测试集中的正常样本，它们的分布是一致的。蓝色五角星是测试集中的异常样本，它们几乎全部分布于正常样本分布的边缘上，呈现明显的特殊性。异常样本和正常样本有较大的区分度，说明基于自编码器的特征变换取得了预期效果。

4.3 异常判别方法

异常判别的任务能看做是一个二分类问题，划分为表 2.4中 TP、FP、TN、FN 这四种情况。将异常视为正类，将正常视为负类，按照 Fish4Knowledge 轨迹数据集论文 [37] 的做法，定义评价指标：

$$\mathrm{TPR} = \frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FP}} \tag{4-10}$$

$$\mathrm{TNR} = \frac{\mathrm{TN}}{\mathrm{TN}+\mathrm{FN}} \tag{4-11}$$

$$\mathrm{TPNR} = \sqrt{\mathrm{TPR}\cdot\mathrm{TNR}} \tag{4-12}$$

TPR 即异常样本/正类的准确率，TPR 降低说明有的异常样本被错误分类成正常样本；TNR 即正常样本/负类的准确率，TNR 降低说明有的正常样本被错误分类成异常样本。TPNR 是综合两者的指标。

4.3.1 基于自编码器重构误差的异常判别

当自编码器训练结束之后，特征变换只利用编码器即可。但如果进而利用解码器尝试恢复出原始的时间序列数据，计算原始数据和重构后数据的 MSE 误差（Mean Square Error，均方误差），正常样本和异常样本之间是否存在区分度呢？实验表明，答案是肯定的。表 4.2展示了不同样本集的重构误差情况。可以明显看出，测试集上正常样本的重构误差稍大于训练集上正常样本的重构误差，这可以归因为训练集和测试集的性能差距，这是机器学习中的普遍现象；测试集上异常样本的重构误差远大于训练集/测试集正常样本的重构误差，这为利用重构误差的差异来判断异常轨迹提供了可能。

设定一个阈值，当某个样本的重构误差大于该阈值时，则认为该样本是异常样本，否则认为是正常样本。改变重构误差阈值，实际上是在 TPR 和 TNR 两者之间权衡，结果如图 4.8所示。

TPNR 在重构误差阈值取 0.42 时最大，此时 TPR=0.9661，TNR=0.9382，TPNR=0.9521。严格来说，重构误差阈值是模型的一个超参数，按机器学习的通常理解，超参数选取的

中国知网 https://www.cnki.net

实验应该利用验证集而不是测试集。但由于数据集数目较少，划分验证集不能使结果更具代表性，因此本小节没有这么做。

表 4.2: 不同样本集的重构误差统计量

样本集	均值	标准差	最小值	中位数	最大值
训练集-正常	0.0950	0.2637	0.0007	0.0276	4.648
测试集-正常	0.1527	0.5240	0.0015	0.0314	12.69
测试集-异常	9.970	47.86	0.1076	2.026	372.9

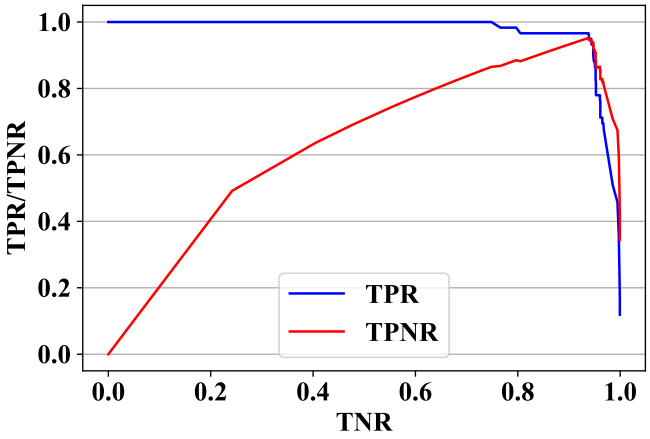


图 4.8: 改变重构误差阈值，正类/负类/综合准确率的变化

4.3.2 基于聚类中心距离的异常判别

尽管基于自编码器重构误差的异常判别方法思路简单，合理利用了解码器模型，但这种方法计算量大，且计算所需的数据多：

- GRU 网络将特征数据恢复为时间序列数据，计算量大，且需要知道原始轨迹数据的长度；
- 重构误差的计算需要知道完整的原始轨迹数据。

因此，找到一种只利用特征数据来完成异常判别的方法，是很有必要的。本小节基于 DBSCAN 聚类（Density-Based Spatial Clustering of Applications with Noise）的思想来继续研究。DBSCAN 方法从密度的角度出发，提出了核心对象、非核心对象、孤立点这一组概念，它们由一组参数 $(\varepsilon, \text{MinPts})$ 决定：

中国知网 https://www.cnki.net

- ε-邻域：到某个样本的距离小于 ε 的区域，叫做该样本的 ε-邻域；
- 核心对象：ε-邻域内有不少于 MinPts 个其他样本，则该样本叫做核心对象；
- 非核心对象：在某个核心对象的 ε-邻域内，但自身不是核心对象，则该样本叫做非核心对象；
- 孤立点：既不是核心对象，也不是非核心对象，则该样本叫做孤立点。

DBSCAN 获得聚类簇的规则是，相连的核心对象及其连接的非核心对象属于同一个簇。但本小节异常判别不需要利用 DBSCAN 完成聚类，而是仅利用 DBSCAN 中核心对象的概念。如前文所述，编码器将训练集的 50% 正常轨迹样本编码为 128 维特征向量，而 DBSCAN 算法能够评测这些特征向量找到一些核心对象样本。将这些样本视为正常轨迹样本的代表，或者叫中心。对于一个新样本，如果它离这些中心足够远，则认为它是一个异常样本。

具体实现时，需要调整一些参数、选择一些组件，比如距离函数、DBSCAN 参数 $(\varepsilon, \text{MinPts})$、异常的判断标准。常见的距离函数有欧式距离、余弦距离等。异常的判断标准，可以是离所有中心的距离的最大值、平均值或大于某个距离的中心数目，另外需要设定相应的阈值作为异常判别的分界点。这些都需要经过实验来确定。最终选取欧氏距离函数，ε=0.5, MinPts=20，运用 DBSCAN 算法得到 41 个核心对象。异常的判断标准是和这 41 个中心的距离平均值大于某个设定的阈值。改变该阈值，准确率的变化如图 4.9所示。TPRN=0.9158 最大，此时 TPR=0.9492，TNR=0.8837。

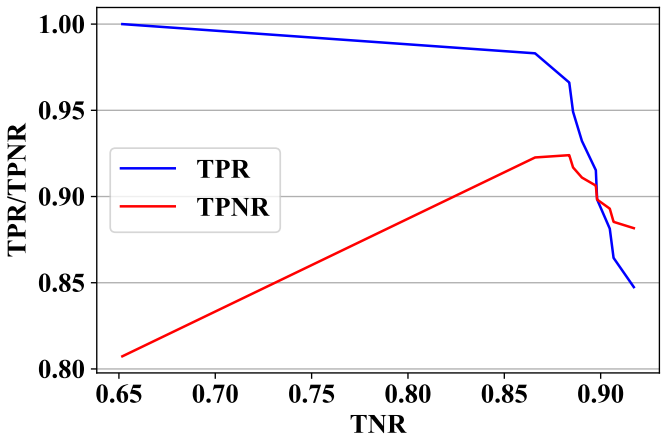


图 4.9: 改变中心距离阈值，正类/负类/综合准确率的变化

k-means 聚类算法也是一种使用广泛的聚类算法。但实验发现，如果将 k-means 聚类算法的 k 个聚类中心作为正常轨迹数据的代表，运用上述的异常判别流程，得到的准

中国知网 https://www.cnki.net

确率比利用 DBSCAN 算法低很多。从聚类思想上看，k-means 适合同一个簇是球状分布的数据，否则簇中心并不能很好地代表簇内的样本。而 DBSCAN 的聚簇过程则依赖于相似关系的传递，对数据的分布形状没有要求。若一个样本的近邻有很多正常样本，那么该样本处于密度高的位置，因此可以作为这些样本的代表。综上所述，DBSCAN 算法更适合本章的轨迹数据集。

4.3.3 结果对比与分析

表 4.3总结了不同方法在 Fish4Knowledge 轨迹数据集上的准确率。原论文方法 (a) 构造了大量的人工特征，将轨迹数据变换为结构化的特征。而本章方法 (b) 和 (c) 的做法是基于自编码器将轨迹数据变换为 128 维特征。从 TPNR 综合准确度上来看，方法 (c) 稍高于方法 (a)，且方法 (b) 比 (a) 和 (c) 高 4 个点左右。这可以说明，自编码器的特征变换方法优于人工特征方法。

表 4.3: 不同方法在 Fish4Knowledge 轨迹数据集上的准确率

方法	TPR	TNR	TPNR
(a) 原论文[37]	0.94	0.88	0.91
(b) 基于重构误差	0.9661	0.9382	**0.9521**
(c) 基于 DBSCAN 聚类	0.9492	0.8837	0.9158

从实际应用角度来看，TPR 应该受到更多的关注，因为异常现象的漏检可能会带来一些严重的后果，而正常现象误认为是异常的危害不大。测试集中 59 个异常轨迹样本，方法 (b) 识别出 57 个，方法 (c) 识别出 56 个，效果均不错。

值得一提的是，实验中也尝试了 LOF、孤立森林等异常检测方法，但效果均不理想。原因可能是，这些方法的参数依赖一些先验的知识、难以调整，且这些方法不能将变换特征包含的信息完全解析出来。而基于重构误差的方法 (b) 效果特别好，是因为编码器-解码器结构经过了训练，通过解码器的作用能够更好地解析变换特征，从而找到一条更细致的正常样本与异常样本的分界线。但针对动态更新的轨迹，解码器必须重新进行完整的计算，因此方法 (b) 不适合下一章的在线监测算法。

中国知网 https://www.cnki.net

4.4 小结

本章讲述了如何对 Fish4Knowledge 轨迹数据集进行异常判别。首先，利用 GRU 设计自编码器网络将轨迹数据变换为 128 维的特征，从 t-SNE 图看出，异常样本的分布具有特殊性。接着，针对 128 维特征，提出了两种方法判断异常，一种是利用解码器恢复出原始数据并计算重构误差，另一种是计算样本与 DBSCAN 所有核心对象的距离。前者的限制较多但准确率更高，且二者均比原论文采用人工特征方法的准确率高。

下一章将综合轨迹提取和异常判别方法，实现一个在线监测算法。

中国知网 https://www.cnki.net

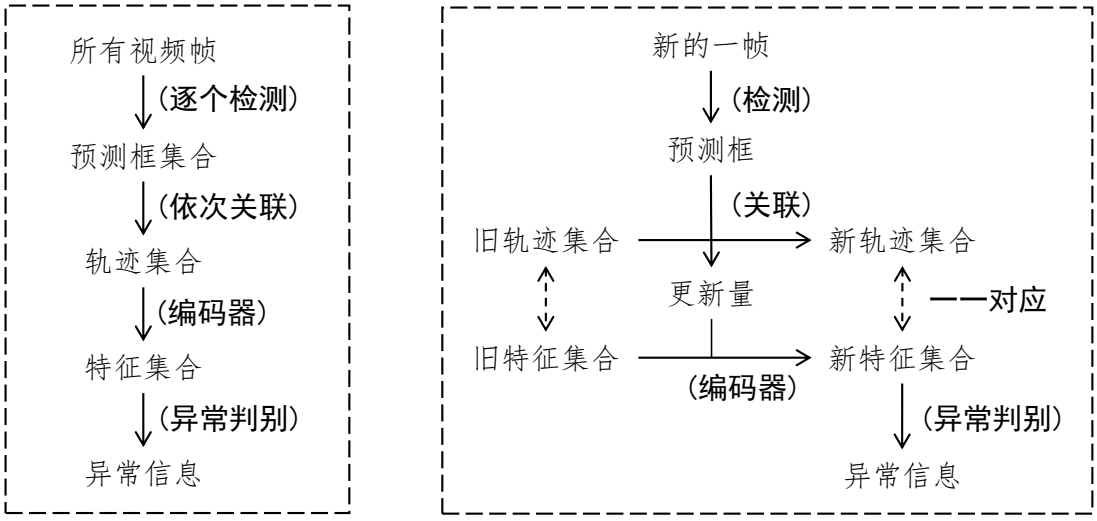
5 鱼类异常行为在线监测

为了完成鱼类异常行为在线监测，本章综合了前面三章的功能模块，并依据在线运行的需求做出相应的修改。

5.1 在线监测算法

5.1.1 在线方式与离线方式的比较

假设有一个摄像头正在拍摄水下鱼群游动的场景，图像一帧一帧被采集到。在线运行方式指的是，每当采集到一帧新的图像，都要立即更新轨迹信息，进而更新异常信息。相比之下，前面三章的功能模块简单串联起来，叫做离线运行方式。



(a) 离线运行（全量形式） (b) 在线运行（增量形式）

图 5.1: 离线/在线运行方式比较

图 5.1(a) 展示了离线运行的完整流程，所有功能模块一次性将工作做完。数据流是单向流动的，非常清晰，视频 → 预测框 → 轨迹 → 特征 → 异常信息。

图 5.1(b) 展示了在线运行时某个时间点的流程，以增量的形式对结果进行更新。其中，有两部分与离线运行时的作用机制几乎相同：(1) 检测模型为每帧图像给出鱼类的预测框；(2) 基于聚类中心距离的异常判别方法依据轨迹变换后的编码特征判断轨迹是否异常。因此重点关注轨迹关联部分和编码器部分的修改。

中国知网 https://www.cnki.net

5.1.2 轨迹关联修改

以二分图的视角来看，离线运行的每次轨迹关联过程中，二分图的左节点是前一帧的预测框集合，二分图的右节点是当前帧的预测框集合。最后通过连接相近的轨迹段、删除较短的轨迹段，对轨迹结果进行优化。在线运行继承了连接操作的思想。与离线运行一样，二分图的右节点是当前帧的预测框集合。但二分图的左节点除了包括前一帧所有的预测框，还继续往前追溯 k 帧未完成匹配的预测框。如果当前帧的预测框匹配到多个时间点前的预测框，则利用式 3-8和式 3-9针对中间帧进行插值，补全轨迹数据。

5.1.3 编码器修改

轨迹数据是时间序列数据，编码器的 GRU 单元能够循环地处理时间序列数据。循环的依据是时间维度，这让编码器能够随着时间的推移而动态更新特征变换的结果。作用机制如图 5.2所示，用式子表示：

$$B_t = \mathrm{GRU}(B_{t-1}, A_t) \tag{5-1}$$

其中 A 是轨迹数据，B_t 是编码器在 t 时刻的编码特征。在 $t-1$ 时刻，轨迹的编码特征是 B_{t-1}，经过异常判别模块可知轨迹的正常/异常状态。t 时刻时，轨迹数据增加了 A_t，对应图 5.1(b) 中的“更新量”（严格来说，“更新量”可能包括多条轨迹的更新，而这里的 A_t 特指一条轨迹的更新）。最终，当前轨迹 $A_1 \sim A_t$ 对应的编码特征 B_t 通过式 5-1一步计算而得。

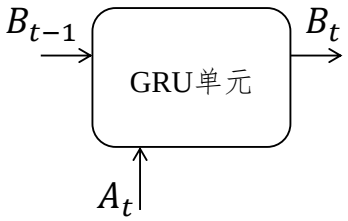


图 5.2: 编码特征的动态更新

代码实现时，需要记录每条轨迹上一时间点的编码特征 B_{t-1}，并将 GRU 网络当作 GRU 单元来使用，即令隐层的初始值 $h_0 = B_{t-1}$，时间序列输入是长度为 1 的 A_t。与每次均采用对整条轨迹数据做变换的方式相比，这种动态更新方式大大减少了重复的计算量。

中国知网 https://www.cnki.net

尽管解码器部分也是 GRU 网络，但它并不能实现结果的动态更新。因为解码器的关键输入是变换特征 B_t，它是不断发生变化的。而基于自编码器重构误差的异常判别方法必须经过解码器恢复原始数据，因此这种方法不适合在线监测算法。

5.1.4 自编码器轨迹训练集制作

在线监测算法是基于 MHK 水下鱼类视频数据集来测试的，需要为自编码器制作相应的轨迹训练集。

Wells Dam 场景的训练集共 18000 张图像，拼接起来是一段 10 分钟的视频（帧率 30 fps）。采用数据集的标注框信息和离线轨迹关联方法，能够从视频中提取出 385 条轨迹数据，它们的长度分布如图 5.3所示，最小长度是 1，最大长度是 297。

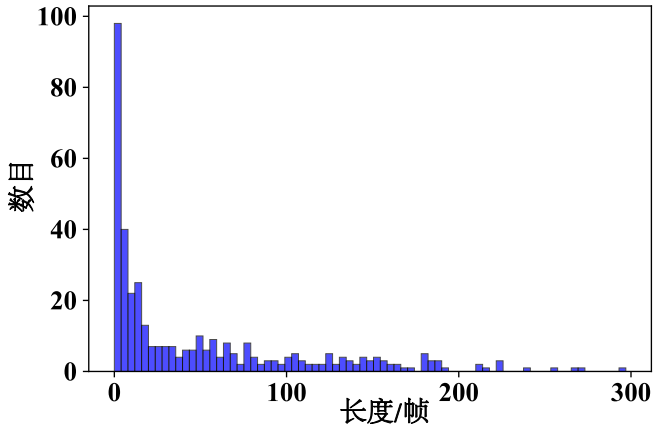


图 5.3: 提取出的轨迹数据长度分布

由于视频不长，且鱼类出现的频率不算高，所以提取出的轨迹数目较少。通过以下方法处理轨迹数据：

- 删掉较短的轨迹。考虑到轨迹较短时携带的信息太少，因此删掉长度小于 10 的轨迹。
- 利用截取的方法产生大量子轨迹。对于长度不小于 30 的轨迹，逐步截取长度为全长的 1/2，3/4 的子轨迹，最终的轨迹数目达到上万条。
- 采样。从上万条轨迹中随机采样出 3000 条作为训练样本。

自编码器的训练数据是无监督的，不需要正常/异常标签信息。而 MHK 数据集不关注鱼类游动是否异常，因此人工设置标签也是不合适的。基于这一点，本章的在线监测算法仅关注整体如何运行，而不关注异常的定义，因此没有准确率这一说法。

中国知网 https://www.cnki.net

5.1.5 异常轨迹的在线判别规则

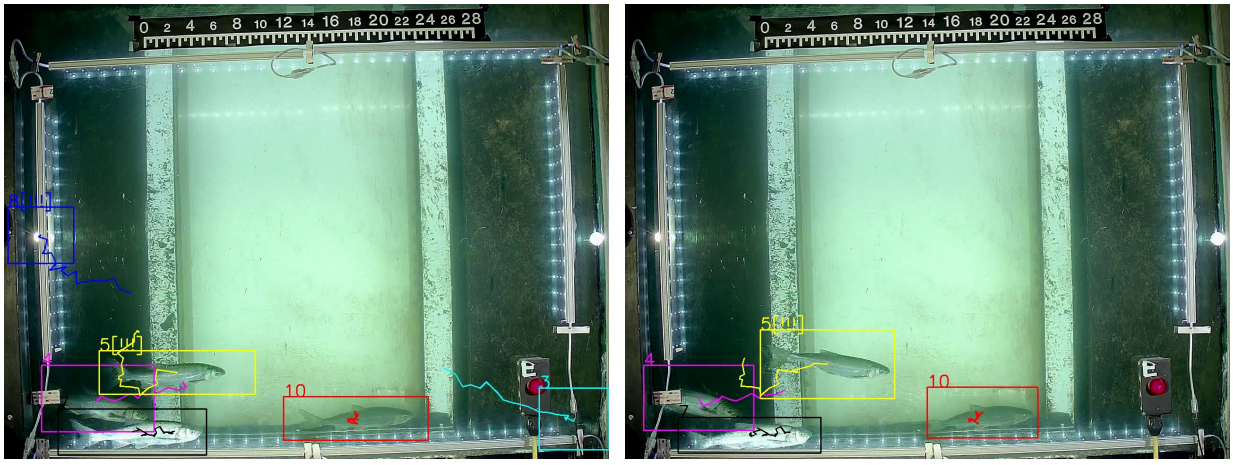
在线运行方式的异常判别与离线运行方式有较大差异。离线运行方式针对的是一条完整的轨迹，而在线运行方式则在轨迹的每个时间点都更新异常信息，由此会带来一些问题。比如，理论上会出现在 $t-1 \sim t+1$ 时刻分别判断为正常 $\rightarrow$ 异常 $\rightarrow$ 正常这种抖动情况。因此，对在线的异常判别添加一些限制：

- 若当前轨迹长度未达到 10，则不进行异常判别，避免信息过少产生无意义的结果；
- 引入滞回特性。对于同一条轨迹，当异常/正常信息连续出现 5 帧或以上，才将输出状态更新为对应的状态。

这样修改之后能够让异常信息更加稳定、合理。对于编码器来说，编码特征更关注最近的数据，之前的状态并不会永久影响之后的状态，因此在线异常判别能够应对长时间尺度的轨迹数据。

5.2 结果与分析

采用本章的在线流程处理第三章的测试视频，结果如图 5.4所示。除了轨迹信息之外，画出了异常信息，如果对应的轨迹被识别为异常，则在左上角添加“[!!!]”标识。蓝色和黄色对应的游动轨迹被标记为异常，原因是它们与训练集中大多数轨迹差异较大。蓝色轨迹晃动比较厉害，而黄色轨迹转角变化较大。



(a) 第 120 帧　　(b) 第 130 帧

图 5.4: 在线运行结果

中国知网 https://www.cnki.net

测试视频共 150 帧，各个功能模块的累计耗时情况如表 5.1所示。计算可知，处理的帧率是 150/19.419=7.72 fps，但其中相当一部分时间花费在读入图像和保存结果上了，这跟实验的硬件条件有关。不考虑读入图像和保存结果的消耗，则理论上算法的处理帧率是 150/10.878=13.79 fps。其中 94% 的时间花费在检测模型上，相比之下，同样包含神经网络的异常判别模块耗时较少，而轨迹关联模块几乎不占时间。因此，如果采取隔帧处理之类的方式减少检测模型的运行次数，那么能够有效地提升算法的处理帧率。这可以作为之后的研究工作。

表 5.1: 在线运行时各个功能模块的耗时情况 (秒)

功能/模块	耗时	占比	占比（不考虑 IO）
读入图像	6.558	33.8%	-
鱼类检测	10.227	52.7%	94.0%
轨迹关联	0.070	0.4%	0.7%
异常判别	0.581	3.0%	5.3%
保存结果	1.983	10.1%	-
总计	19.419	100%	100%

5.3 小结

本章初步实现了一个适合在线监测的算法，主要修改了轨迹关联方法和编码器计算方式，并构造轨迹训练集，完善了轨迹异常判断规则，最终在 MHK 视频数据上进行了整体测试。该算法能够完成水下鱼类异常行为在线监测的任务。

中国知网 https://www.cnki.net

6 总结与展望

6.1 全文总结

本文基于 MHK 水下鱼类视频数据集和 Fish4Knowledge 水下鱼类轨迹数据集，研究的主要内容是基于轨迹提取的鱼类异常行为判别，研究路线是：先利用目标检测模型和关联方法从视频中提取出鱼类的游动轨迹，再依据轨迹信息判断是否异常。

具体来讲，本文的工作有以下几个部分：

(1) 将 Faster RCNN 目标检测模型应用于水下鱼类图像，利用数据增强提升了模型在测试集上的性能，并详细分析了模型在某些图像上的错误。模型的效果优于原论文，这为之后的轨迹关联打下了基础。

(2) 提出了一种关联检测结果获取游动轨迹的方法。首先依据相似程度定义两个预测框的关联度，之后利用匈牙利算法或贪心算法进行预测框的匹配，最后用连接和删除两种方法优化轨迹提取结果。结果表明，这种轨迹关联方法能够正确地从视频中提取鱼类的游动轨迹，并且在检测模型的基础上提升了整体的 AP 指标。

(3) 提出了一种无监督的针对时间序列型轨迹数据的异常判别方法。首先利用 GRU 网络构造自编码器模型，训练数据是无类别标签的。之后将编码器作为特征变换模型，并提出了自编码器重构误差和聚类中心距离两种异常判别的标准。结果表明，这种特征变换方法优于原论文的人工特征方法，异常判别方法能够有效捕捉到异常轨迹。

(4) 在前面工作的基础上，初步实现了一种在线监测鱼类异常行为的算法，分析了在线运行方式存在的问题并提出了解决方案。

6.2 下一步的研究方向

本文的研究仍有一些不足之处，这些方面可以作为下一步的研究方向：

(1) 针对密集场景优化轨迹提取算法。本文的轨迹提取方法在鱼类游动密集的区域效果较差，因此如何提升这类场景中的性能是研究的一个方向。

(2) 采用集成学习的思路来处理轨迹。单一的轨迹异常判别方法性能有限，可以继续研究用集成学习融合多个不同的模型来提升性能。

中国知网 https://www.cnki.net

(3) 提升在线算法的速度。本文实现的鱼类异常行为在线监测算法在速度上仍有较大的优化空间，比如深度学习模型的压缩量化、视频的隔帧处理模式等。

(4) 精细化应用场景。本文的研究对象是公开的网络数据集，因此缺乏对应用方面细节问题的讨论。在具体的应用场景中，能够提出更具针对性的解决方案，并得到良好的反馈。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

参考文献

[1] 平瑛, 刘丹丹. 中国渔业生产经营组织化探索 70 年[J]. 中国农村经济, 2019(11): 16-31.

[2] 罗茵. 《2020 中国渔业统计年鉴》出版广东水产品总产量首次全国第一[J]. 海洋与渔业, 2020(6): 12-13.

[3] 侯晓娇. 基于计算机视觉的鱼群行为检测与结构特征研究[D]. 太原科技大学, 2014.

[4] Hassan S G, Hasan M, et al. Information fusion in aquaculture: A state-of the art review[J]. Frontiers of Agricultural Science and Engineering, 2016, 3(3): 206-221.

[5] 林森, 赵颍, 等. 水下光学图像中目标探测关键技术研究综述[J]. 激光与光电子学进展, 2020, 57(6): 26-37.

[6] Zion B. The use of computer vision technologies in aquaculture–a review[J]. Computers and Electronics in Agriculture, 2012, 88: 125-132.

[7] Mallet D, Pelletier D. Underwater video techniques for observing coastal marine biodiversity: a review of sixty years of publications (1952–2012)[J]. Fisheries Research, 2014, 154: 44-62.

[8] 段延娥, 李道亮, 李振波, 等. 基于计算机视觉的水产动物视觉特征测量研究综述[J]. 农业工程学报, 2015, 31(15): 1-11.

[9] 张胜茂, 张衡, 唐峰华, 等. 计算机视觉技术在监测鱼类游泳行为中的研究进展[J]. 大连海洋大学学报, 2017, 32(4): 494-501.

[10] 邢俊, 李庆武, 何飞佳, 等. 基于智能视觉物联网的水产养殖监测系统[J]. 应用科技, 2017, 44(5): 46-51.

[11] Papadakis V M, Papadakis I E, Lamprianidou F, et al. A computer-vision system and methodology for the analysis of fish behavior[J]. Aquacultural Engineering, 2012, 46: 53-59.

[12] Papadakis V M, Glaropoulos A, Kentouri M. Sub-second analysis of fish behavior using a novel computer-vision system[J]. Aquacultural Engineering, 2014, 62: 36-41.

[13] 江丹丹, 桂福坤. 基于视频图像的鱼类行为轨迹追踪[J]. 浙江海洋学院学报: 自然科学版, 2015, 34(2): 112-118.

中国知网 https://www.cnki.net

[14] Spampinato C, Chen-Burger Y H, Nadarajan G, et al. Detecting, tracking and counting fish in low quality unconstrained underwater videos[C]//3rd International Conference on Computer Vision Theory and Applications (VISAPP): vol. 2. 2008: 514-519.

[15] 于欣, 侯晓娇, 卢焕达, 等. 基于光流法与特征统计的鱼群异常行为检测[J]. 农业工程学报, 2014, 30(2): 162-168.

[16] Sadoul B, Mengues P E, Friggens N C, et al. A new method for measuring group behaviours of fish shoals from recorded videos taken in near aquaculture conditions[J]. Aquaculture, 2014, 430: 179-187.

[17] 卢焕达, 于欣, 刘广强. 基于图像处理和压缩感知的鱼群低溶氧胁迫异常行为检测方法[J]. 浙江大学学报 (农业与生命科学版), 2018, 44(4): 499-506.

[18] Deep B V, Dash R. Underwater fish species recognition using deep learning techniques[C]//2019 6th International Conference on Signal Processing and Integrated Networks (SPIN). 2019: 665-669.

[19] Li X, Shang M, Qin H, et al. Fast accurate fish detection and recognition of underwater images with fast r-cnn[C]//OCEANS 2015-MTS/IEEE Washington. 2015: 1-5.

[20] Xu W, Matzner S. Underwater fish detection using deep learning for water power applications[C]//2018 International Conference on Computational Science and Computational Intelligence (CSCI). 2018: 313-318.

[21] Peng C, Duarte C M, Costa D P, et al. Deep learning resolves representative movement patterns in a marine predator species[J]. Applied Sciences, 2019, 9(14): 29-35.

[22] Li B, Yan J, Wu W, et al. High performance visual tracking with siamese region proposal network[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 8971-8980.

[23] Li B, Wu W, Wang Q, et al. Siamrpn++: Evolution of siamese visual tracking with very deep networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2019: 4282-4291.

[24] Bewley A, Ge Z, Ott L, et al. Simple online and realtime tracking[C]//2016 IEEE International Conference on Image Processing (ICIP). 2016: 3464-3468.

中国知网 https://www.cnki.net

[25] Wojke N, Bewley A, Paulus D. Simple online and realtime tracking with a deep association metric[C]//2017 IEEE International Conference on Image Processing (ICIP). 2017: 3645-3649.

[26] Russakovsky O, Deng J, Su H, et al. Imagenet large scale visual recognition challenge[J]. International Journal of Computer Vision, 2015, 115(3): 211-252.

[27] Kang K, Li H, Yan J, et al. T-cnn: Tubelets with convolutional neural networks for object detection from videos[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2017, 28(10): 2896-2907.

[28] Belhassen H, Zhang H, Fresse V, et al. Improving video object detection by seq-Bbox matching[C]//14th International Conference on Computer Vision Theory and Applications (VISAPP). 2019: 226-233.

[29] Zhu X, Wang Y, Dai J, et al. Flow-guided feature aggregation for video object detection[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 408-417.

[30] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 39(6): 1137-1149.

[31] He K, Gkioxari G, Dollár P, et al. Mask r-cnn[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 2961-2969.

[32] Redmon J, Farhadi A. Yolov3: An incremental improvement[J]. ArXiv preprint arXiv:1804.02767, 2018.

[33] Liu W, Anguelov D, Erhan D, et al. SSD: Single shot multibox detector[C]//European Conference on Computer Vision. 2016: 21-37.

[34] Breunig M M, Kriegel H P, Ng R T, et al. LOF: identifying density-based local outliers[C]//Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data. 2000: 93-104.

[35] Liu F T, Ting K M, Zhou Z H. Isolation-based anomaly detection[J]. ACM Transactions on Knowledge Discovery from Data (TKDD), 2012, 6(1): 1-39.

中国知网 https://www.cnki.net

[36] Beyan C, Fisher R B. A filtering mechanism for normal fish trajectories[C]//Proceedings of the 21st International Conference on Pattern Recognition (ICPR2012). 2012: 2286-2289.

[37] Beyan C, Fisher R B. Detection of abnormal fish trajectories using a clustering based hierarchical classifier[C]//British Machine Vision Conference (BMVC). 2013.

[38] Li C, Han Z, Ye Q, et al. Abnormal behavior detection via sparse reconstruction analysis of trajectory[C]//2011 Sixth International Conference on Image and Graphics. 2011: 807-810.

[39] 李明之, 马志强, 单勇, 等. 基于轨迹分析的交通目标异常行为识别[J]. 电视技术, 2012, 36(1): 106-112.

[40] Spampinato C, Palazzo S, Boom B, et al. Overview of the LifeCLEF 2014 fish task[C]//CEUR Workshop Proceedings: vol. 1180. 2014: 616-624.

[41] Joly A, Goëau H, Glotin H, et al. Lifeclef 2017 lab overview: multimedia species identification challenges[C]//International Conference of the Cross-Language Evaluation Forum for European Languages. 2017: 255-274.

[42] Boom B J, Huang P X, He J, et al. Supporting ground-truth annotation of image datasets using clustering[C]//Proceedings of the 21st International Conference on Pattern Recognition (ICPR2012). 2012: 1542-1545.

[43] Anantharajah K, Ge Z, McCool C, et al. Local inter-session variability modelling for object classification[C]//IEEE Winter Conference on Applications of Computer Vision. 2014: 309-316.

[44] Cutter G, Stierhoff K, Zeng J. Automated detection of rockfish in unconstrained underwater videos using Haar cascades and a new image dataset: Labeled fishes in the wild[C]//2015 IEEE Winter Applications and Computer Vision Workshops. 2015: 57-62.

[45] Pedersen M, Bruslund Haurum J, Gade R, et al. Detection of marine animals in a new underwater dataset with varying visibility[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops. 2019: 18-26.

[46] Saleh A, Laradji I H, Konovalov D A, et al. A realistic fish-habitat dataset to evaluate algorithms for underwater visual analysis[J]. Scientific Reports, 2020, 10(1): 1-10.

中国知网 https://www.cnki.net

[47] Chen K, Wang J, Pang J, et al. MMDetection: Open MMLab detection toolbox and benchmark[J]. ArXiv preprint arXiv:1906.07155, 2019.

[48] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.

[49] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 2117-2125.

[50] Deng J, Dong W, Socher R, et al. Imagenet: A large-scale hierarchical image database[C]//2009 IEEE Conference on Computer Vision and Pattern Recognition. 2009: 248-255.

[51] Padilla R, Netto S L, da Silva E A. A survey on performance metrics for object-detection algorithms[C]//2020 International Conference on Systems, Signals and Image Processing (IWSSIP). 2020: 237-242.

[52] Everingham M, Van Gool L, Williams C K, et al. The pascal visual object classes (voc) challenge[J]. International Journal of Computer Vision, 2010, 88(2): 303-338.

[53] Lin T Y, Maire M, Belongie S, et al. Microsoft coco: Common objects in context[C]//European Conference on Computer Vision. 2014: 740-755.

[54] Fisher R B, Chen-Burger Y H, Giordano D, et al. Fish4Knowledge: collecting and analyzing massive coral reef fish video data[M]. Springer, 2016.

[55] Fish trajectory ground truth dataset[Z]. http://groups.inf.ed.ac.uk/f4k/GROUNDTRUTH/BEHAVIOR. 2014.

[56] Tavenard R, Faouzi J, Vandewiele G, et al. Tslearn, a machine learning toolkit for time series data[J]. Journal of Machine Learning Research, 2020, 21(118): 1-6.

[57] Paparrizos J, Gravano L. K-shape: Efficient and accurate clustering of time series[C]//Proceedings of the 2015 ACM SIGMOD International Conference on Management of Data. 2015: 1855-1870.

[58] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.

[59] Chung J, Gulcehre C, Cho K, et al. Empirical evaluation of gated recurrent neural networks on sequence modeling[J]. ArXiv preprint arXiv:1412.3555, 2014.

中国知网 https://www.cnki.net

[60] Williams R J, Zipser D. A learning algorithm for continually running fully recurrent neural networks[J]. Neural Computation, 1989, 1(2): 270-280.

[61] Maaten L v d, Hinton G. Visualizing data using t-SNE[J]. Journal of Machine Learning Research, 2008, 9: 2579-2605.

中国知网 https://www.cnki.net

攻读硕士学位期间的主要成果

发表论文：

1. Li X , Liu M , Zhang S , et al. Fish trajectory extraction based on object detection[C]// 2020 39th Chinese Control Conference (CCC). 2020:6584-6588.

参与项目：

1. NSFC—浙江两化融合联合基金项目（重点支持项目）：基于水下无线传感器网络的深水网箱养殖智能化监测关键技术研究（项目编号：U1809212），2019/01–2022//12.
2. 浙江省重点研发计划项目：面向现代渔业与航海安全的信息化装备技术与应用示范—基于大洋烽火台的商用海洋信息监测潜浮标系统（项目编号：2018C03030），2017/09–2020/12.

中国知网 https://www.cnki.net